Université Abdelmalek Essaadi
Faculté des Sciences de Tétouan
Département d'Informatique




# Bases de Données Avancées

M. BELLAJ Mohamed

A.U 2026/2027

# Chapitre 1 : Généralité sur les systèmes d'informations

# Plan

- Définition d'un système d’information
- Le rôle du système d'information
- Data management sur le SI
- Les usages du Big Data
- Le reporting d’organisation
- L’analyse en temps réel
- Data Discovery ou exploration de données
- L’analyse prédictive
- Contraintes sur le SI
- Data Warehouse
- Data Lake

## Les systèmes d’information

**leurs outils informatiques**

les applications boîte mail, outils de conférence en ligne, systèmes de gestion de production.

**sont omniprésents**

- dans notre société.
- dans votre usage quotidien avec les montres connectées, le GPS…
- dans celui des entreprises, même la plus petite, les systèmes d’information jouent désormais un rôle central dans la vie économique et sociale !

# Système d’information

le terme de système d’information a tendance à nous faire croire qu’il s’agit d’un système unique, généralement un logiciel.

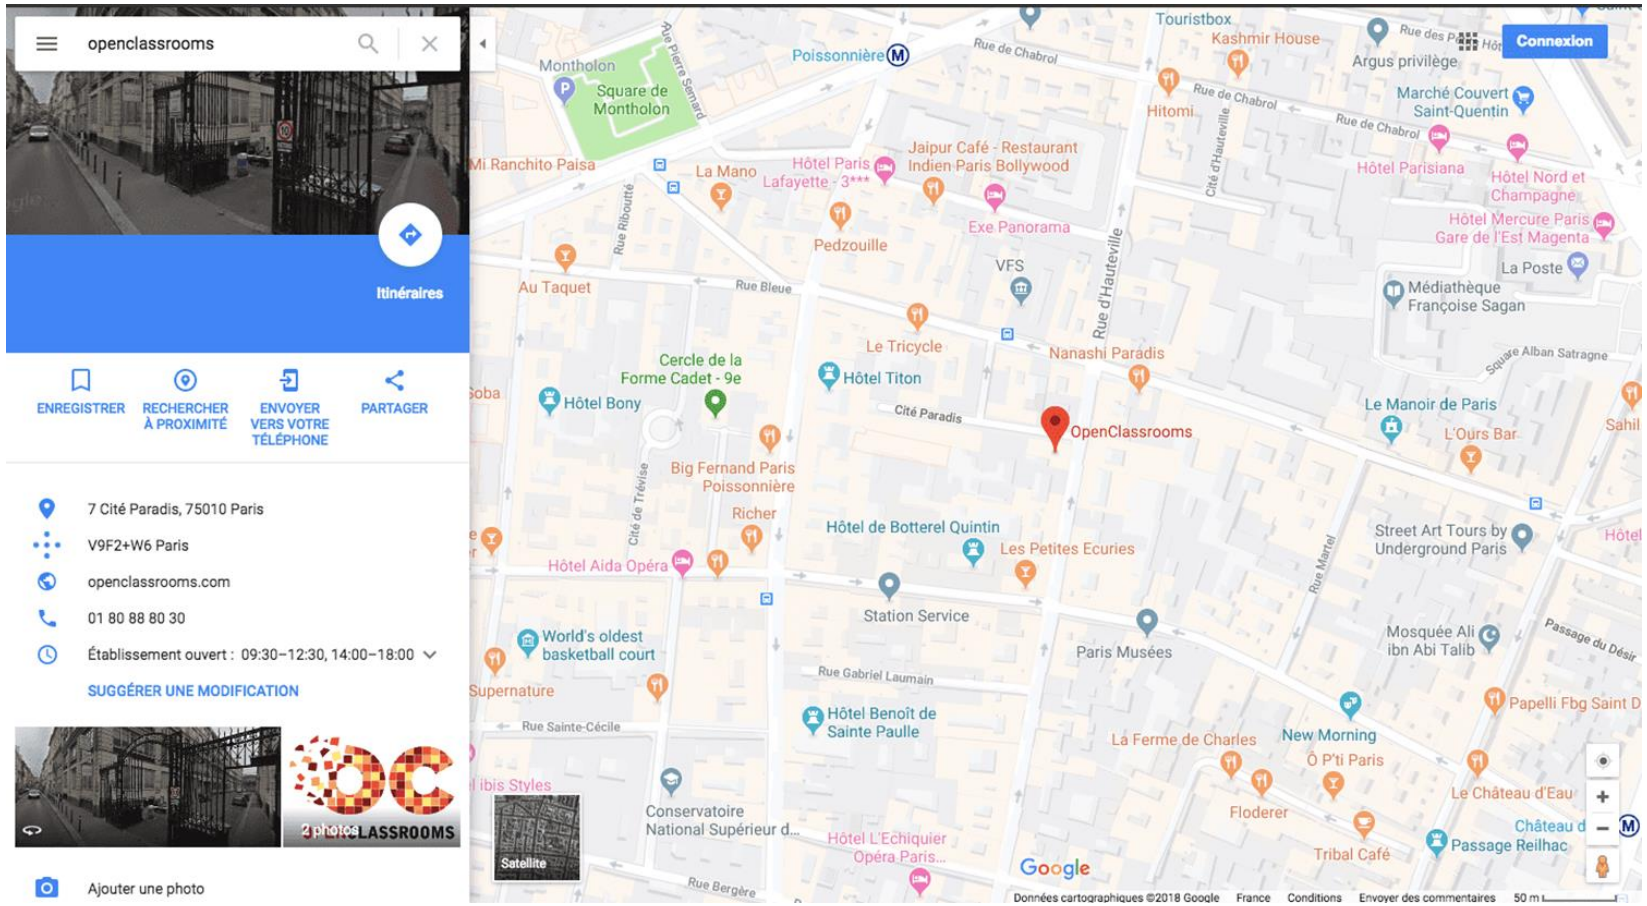
En réalité, cette vision simpliste est erronée.

Un SI est un environnement bien plus complexe.il faut le voir comme un ensemble de ressources, à la fois humaines, matérielles et immatérielles, dont le rôle est de collecter, stocker, traiter et distribuer de l’information.

# Système d'information

Exemple : le service de cartographie Google Maps.

c'est un site de cartographie en ligne qui vous permet de rechercher un lieu, n'importe où dans le monde, depuis la barre de recherche sur le site.



# Système d’information

En plus d’être un service de Google, Google Maps est un système d’information à part entière.

qu'est-ce qui fait de ce service un SI ?

il permet de :

- collecter et stocker les données cartographiques prises par les satellites ;
- les traiter en les combinant à vos recherches sur le site ;
- et les distribuer, c’est-à-dire vous les afficher sur le site lors de vos recherches ;

# Système d’information

c’est un système d’information parce que **Google Maps** est un ensemble de ressources humaines, matérielles et immatérielles :

- Des ressources **humaines**, car Google Maps, c’est une équipe de développeurs, de cartographes, de géomètres, mais aussi les chauffeurs des voitures Google qui prennent les rues en photo, et encore bien d’autres personnes !
- Des ressources **matérielles**, car des ordinateurs, serveurs, caméras, satellites sont utilisés pour acquérir et stocker les données cartographiques.
- Des ressources **immatérielles**, car Google Maps, c’est aussi des photos satellites, des cartes, mais également des brevets créés et exploités par Google pour mettre en œuvre ce service.

# Le rôle du système d'information

L’apparition d’Internet a eu un impact fort sur l’évolution technique des systèmes d´information et leurs enjeux pour les entreprises.

Le SI permet **d'automatiser** et de **dématérialiser** quasiment toutes les opérations incluses dans les activités ou procédures de notre vie quotidienne personnelle ou professionnelle.

# Le rôle du système d'information

un SI est formé de l'ensemble de ressources **(les personnes, les matériels, les logiciels, les procédures)** permettant de mener les actions suivantes sur l'information :

**(1) COLLECTER => (2) STOCKER => (3) TRAITER => (4) DIFFUSER**

# Le rôle du système d'information

SI soit en contact avec d’autres SI

Exemple :

lorsque les entreprises ont pour obligation de faire tous les mois la déclaration (CNSS), elles ne communiquent pas les données de leurs employés manuellement à l’administration.

Leur logiciel transmet directement ces données à l’administration en utilisant une API.

Dans ce cas, les SI en question doivent être capables de communiquer ensemble.

**On parle alors d’interopérabilité.**
**Cette interopérabilité est possible grâce aux API.**

# Le rôle du système d'information

## Une API, c’est quoi ?

"API" est l’abréviation de « **Application Programming Interface** ». C’est une relation entre deux systèmes informatiques qui leur permet de communiquer et d’échanger des informations.

# Data management sur le SI

## Des chiffres

### Chaque minute

environ 350 000 tweets

15 millions de SMS

200 millions de mails sont envoyés au niveau mondial.

### Pendant le même laps de temps :

des dizaines d'heures de vidéos sont mises en ligne sur YouTube,

des centaines de milliers de nouveaux fichiers sont archivés sur les serveurs de Facebook.

# Data management sur le SI

Les nouveaux usages

- une sauvegarde des films sur un disque dur externe ?
- Une photo partagée sur les réseaux sociaux ou une géolocalisation depuis votre smartphone ?

Ce sont autant de données qui viennent s'ajouter à la masse enregistrée sur les ordinateurs et les serveurs du monde entier.

Même la façon de les interroger devient information : notre historique de navigation sur le Web, nos recherches sur Google…

le **Big Data**
dont l'exploration est en train de créer une nouvelle science qui chamboulera profondément le fonctionnement des organisations.

# Data management sur le SI

Toutes ces données sont produites en temps réel par l'ensemble des SI installés dans le monde.

Eux-mêmes sont composés des éléments les plus divers :

- des automates industriels,
- des robots,
- des téléphones,
- des caméras,
- des objets connectés,
- des capteurs,
- des puces électroniques…

# Data management sur le SI

On peut distinguer deux grandes familles de données :

**celles qui ne nous concernent pas directement en tant qu'être humain**.

- Il s'agit principalement des données d'ordre technique et scientifique ;

**celles dont nous sommes en réalité la matière première**.

- Il s'agit des données que nous fournissons, volontairement ou pas tout au long de notre vie quotidienne.
- Il peut s'agir de nos déplacements, de la musique que l'on écoute, des séries qu'on regarde, de ce qu'on achète, de ce qu'on lit, des sites Web que l'on visite ou des photos que l'on poste sur son réseau social préféré.

# Les usages du Big Data

Aujourd'hui, l'enjeu est de pouvoir exploiter le plus finement possible ces données.

Pour cela, le **Big Data** offre différents usages aux entreprises :

- le reporting d'organisation ;
- l'analyse en temps réel ;
- la data discovery ou exploration de données ;
- l'analyse prédictive.

# Le reporting d'organisation

Dans toute entreprise ou organisation, les équipes de direction ont besoin d'informations **concrètes** et **chiffrées** pour définir ou évaluer une **stratégie**.

Elles ont besoin que leur équipe mette régulièrement à la disposition d'un grand nombre de personnes des rapports de suivi et de pilotage de l'organisation, dont les chiffres sont :

- **vérifiés** et **validés** ;
- **reproductibles** dans le temps (une même analyse produite à des périodes différentes doit présenter les mêmes résultats) ;
- **auditables** (le cheminement pour générer le résultat est connu et documenté).

# Le reporting d’organisation

l'intérêt pour la direction d’une entreprise de disposer d’éléments chiffrés par pays ou par région dans le cas du lancement d’un nouveau produit à l'échelle mondiale.

# L’analyse en temps réel

Il consiste à mener des analyses en temps réel (ou micro-batch à fréquence déterminée)

- l’application d’algorithmes qui va :
  - permettre d’anticiper la survenance de ces défaillances,
  - déterminer plus efficacement les politiques de maintenance préventive.

- Les données exploitées sont, de manière générale, **brutes** et adressées via des développements spécifiques.

# La « Data Discovery » ou exploration de données

**Démocratisation de la donnée :** Permettre aux analystes et aux utilisateurs métiers (Business Intelligence) d'accéder aux données et de les explorer sans dépendre systématiquement des équipes techniques/IT.

**Prise de décision éclairée :** Identifier rapidement des opportunités, des leviers de performance ou des risques cachés au sein de volumétries importantes.

**Gouvernance et cartographie :** Localiser où se trouvent les données sensibles ou stratégiques dans l'entreprise (data lineage, catalogues de données).

# La « Data Discovery » ou exploration de données

- Ces solutions cherchent à libérer les utilisateurs des contraintes imposées par les sources de données et les logiciels associés.

**Comment font-elles cela ?**

- Par la possibilité qu'elles ont d'analyser elles-mêmes et sans recours aux équipes informatiques les données dont elles ont besoin

- La population susceptible d'exploiter ces solutions est plus restreinte et de type **analyste** ou **administrateur fonctionnel de données**.

# La « Data Discovery » ou exploration de données

***Exemple :***

- la police utilise ces techniques pour caractériser les crimes et les comportements des criminels afin de prévenir le crime, et limiter les risques et les dangers pour la population.
- Les entreprises de marketing utilisent l'exploration de données pour réduire le coût d'acquisition d'un nouveau client.

# L’analyse prédictive

- Dans le prolongement de la data discovery, la multitude des données existantes et utilisables par l’organisation permet plus facilement de mettre en œuvre des **algorithmes statistiques** et **prédictifs**.

- L’objectif est d’identifier des corrélations et des schémas reproductibles que l’on n’aurait pas détectés naturellement, et qui permettent d’établir des projections réalistes sur les situations à venir.

# L’analyse prédictive

**Exemple :**

- Dans le domaine **financier**, chaque portefeuille contient en son sein un ensemble de clients à risque qui ne remplissent pas leurs obligations à temps.
- L'institution financière doit entreprendre des actions de recouvrement pour encaisser les sommes dues.
- Un grand nombre de ressources est gaspillé pour des clients dont les sommes dues sont difficiles, voire impossibles à recouvrir.
- L'analyse prédictive peut aider à optimiser les sommes allouées au recouvrement en identifiant les agences les plus efficaces, les stratégies de contact, les actions judiciaires et autres pour chaque client, afin d'augmenter le taux de recouvrement tout en réduisant les coûts.

# L’analyse prédictive

**Exemple :**

- Un autre secteur utilise cette méthode : le secteur de la santé, pour anticiper les évolutions probables de certaines maladies.
- Le secteur de l'énergie est également un domaine d'application important, avec notamment le développement de réseaux électriques intelligents, les « smart grids».
- La consommation d'énergie peut en effet être estimée sur la base de schémas de comportement des clients enregistrés, afin de réguler avec précision l'apport nécessaire d'énergie.

# L’analyse prédictive

- Ces analyses sont majoritairement réalisées par des **profils experts**.
- La population d’utilisateurs est relativement restreinte, de type **statisticien** ou « **Data Scientist** ».
- Ces experts sont parfois dans les équipes marketing ou au sein de la DSI.
- Ils travaillent sur des développements spécifiques ou des solutions de « Data Science » (comme DataIku, Alteryx, RapidMiner…) et des langages statistiques comme R.

# Contraintes sur le SI

- Techniques et Technologiques(**Performance et Temps de Réponse,…)**
- Sécurité et de Confidentialité
- Légales et Réglementaires(**Protection des Données Personnelles,…)**
- Budgétaires et Financières(**Coûts d'Acquisition et de Déploiement,…)**
- Humaines et Organisationnelles(**Compétences et Formation ,…)**

# Le Data Warehouse

Le Data Warehouse, littéralement **l'entrepôt de données**, est une base de données relationnelle, pensée et conçue pour :

- les requêtes et les analyses de données ;
- la prise de décision ;
- les activités de type Business Intelligence davantage que pour le traitement de transactions ou autres usages traditionnels des bases de données.

# Le Data Warehouse

- En plus d'une base de données relationnelle, un environnement Data Warehouse intègre un outil **d'extraction**, de **transport**, de **transformation** et de **chargement de données** (ETL).

- On retrouve aussi des outils d'analyse client et d'autres applications permettant de gérer le traitement des données collectées.

# Le Data Warehouse

- Les informations stockées dans le Data Warehouse sont historisées, et offrent une vue d'ensemble des différentes transactions qui ont eu lieu au fil du temps.

- Les données redondantes sont souvent incluses dans les Data Warehouses pour offrir aux utilisateurs plusieurs vues sur l'information.

# Le Data Warehouse

- En plus d'une base de données relationnelle, un environnement Data Warehouse intègre un outil **d'extraction**, de **transport**, de **transformation** et de **chargement de données** (ETL).

- On retrouve aussi des outils d'analyse client et d'autres applications permettant de gérer le traitement des données collectées.

# Le Data Lake

- Les Data Lakes sont une évolution naturelle de la technologie Big Data.
- Il s'agit d'un nouveau concept de stockage de données qui s'inscrit dans une logique contemporaine d'agilité et d'optimisation dans la gestion de données.
- Un Data Lake repose sur la possibilité de fournir un stockage **global** de l'ensemble des données présentes dans l'entreprise tout en y effectuant le **moins de traitements possible**.

# Le Data Lake

Les données ainsi stockées sans classification, peuvent être de tout type :

- des données **structurées** venant d'une base de données relationnelle comme MySQL ou SQL Server ;
- des données **semi-structurées** (CSV, XML, JSON…) ;
- des données **non structurées** (e-mail, PDF, documents…) ;
- des données **binaires** (images, audios, vidéos…).

# Le Data Lake

- Cette absence de structure de stockage autorise plus de flexibilité dans l'interaction entre les données.
- Outre le stockage, l'intérêt va être de faciliter le traitement et la transformation des données.

# Big Data

- Le Big Data représente l'accumulation de données produites par l'utilisation de tous les SI qui nous entourent.
- L'utilisation du Big Data peut servir à :
  - ✓ la production de rapport afin d'aider dans la prise de décision ;
  - ✓ l'analyse en temps réel pour surveiller et anticiper des comportements à venir, comme la panne d'un moteur ;
  - ✓ aider des populations non techniques dans la découverte de nouvelles données ;
  - ✓ prévoir des situations à venir, comme la météo par exemple.
- Les données exploitées par le Big Data sont regroupées dans des Data Warehouse ou des Data Lakes afin de les rendre plus facilement accessibles.
- Le Big Data représente un enjeu majeur pour le SI, car il impacte fortement les architectures et les usages des entreprises.

## Les 5 V du Big Data

Le Data Lake répond particulièrement aux défis du **Volume** (pétaoctets), de la **Variété** (formats multiples) et de la **Vélocité** (flux en temps réel).

tandis que le Warehouse garantit la **Véracité** (données fiables et nettoyées) pour créer de la **Valeur**.

## En résumé

Le **Big Data** représente l'écosystème global des données massives, rapides et variées que les logiciels traditionnels ne peuvent pas gérer. Pour stocker et analyser ces informations, les entreprises utilisent deux stratégies de stockage fondamentales : **le Data Lake (lac de données)** et le **Data Warehouse (entrepôt de données)**.

# En résumé

La différence principale réside dans la préparation :

- un data lake stocke des données brutes et **non filtrées** pour une exploration future
- Un data warehouse stocke des données hautement **raffinées et structurées**, optimisées pour les rapports décisionnels.

| Caractéristique | Data Lake | Data Warehouse |
|---|---|---|
| **Structure des données** | Données brutes, non structurées ou semi-structurées (images, vidéos, logs, JSON, CSV). | Données hautement structurées, nettoyées et modélisées (tables relationnelles). |
| **Paradigme de Schéma** | **Schéma à la lecture** : la structure est appliquée au moment de la requête. | **Schéma à l'écriture** : les données doivent respecter un modèle strict *avant* le stockage. |
| **Pipeline de données** | **ELT** (Extraire, Charger, puis Transformer plus tard selon les besoins). | **ETL** (Extraire, Transformer pour s'adapter au schéma, puis Charger). |
| **Utilisateurs principaux** | Data Scientists, ingénieurs ML (Machine Learning) et Data Engineers. | Analystes business (BI), décideurs et développeurs de tableaux de bord. |
| **Cas d'usage courants** | Machine Learning, IA prédictive, analyse de flux en temps réel, archivage brut. | Rapports opérationnels, analyses de performances (KPI), requêtes SQL rapides. |
| **Coût de stockage** | **Faible** (utilise du stockage objet cloud bon marché, comme le stockage de masse). | **Plus élevé** (nécessite un stockage relationnel spécialisé et haute performance). |
| **Exemples de Tech** | Amazon S3, Azure Data Lake Storage (ADLS), Apache Spark. | Snowflake, Google BigQuery, Amazon Redshift. |

# L'analogie pour comprendre le Big Data

Pour visualiser le lien avec le **Big Data**, imaginez que les données sont de l'eau :

- **Le Data Lake** est un immense réservoir naturel. Il recueille toute l'eau qui arrive (pluie, rivières, boue) sans la filtrer. C'est très économique, mais vous avez besoin d'outils spécialisés (**comme des scientifiques ou du matériel de filtrage avancé**) pour aller chercher ce dont vous avez besoin et l'analyser.

- **Le Data Warehouse** est une usine de mise en bouteille. Elle prend de l'eau, élimine toutes les impuretés, la teste, et la range dans des bouteilles identiques sur des étagères bien organisées. C'est plus cher à gérer, mais n'importe qui peut entrer et prendre immédiatement une boisson propre et fiable (lancer une requête SQL pour un rapport d'activité).

# La tendance moderne : Le Data Lakehouse

Aujourd'hui, ces deux mondes fusionnent. Les entreprises adoptent de plus en plus le **Data Lakehouse** (popularisé par Databricks). Cette architecture hybride permet de faire des requêtes SQL ultra-rapides et d'appliquer une gouvernance stricte (comme dans un warehouse) directement sur du stockage brut et économique (comme dans un lake).

# Quizz

## Question 1 : Le concept fondamental

*Pourquoi une entreprise ne peut-elle pas simplement utiliser un logiciel classique (comme Microsoft Excel ou une petite base de données Access) pour gérer du Big Data ?*

Les logiciels classiques sont limités par les **3 V** du Big Data :

**Le Volume :** Une feuille Excel est limitée à environ 1 million de lignes. Le Big Data traite des milliards de lignes.

**La Vitesse :** Les outils classiques plantent ou deviennent extrêmement lents lorsque les données arrivent en continu et en temps réel (ex: capteurs IoT, flux Twitter).

**La Variété :** Excel ne peut pas stocker ou analyser directement des formats non structurés comme des vidéos, des images ou des fichiers audio. Le Big Data nécessite donc des technologies de stockage et de calcul distribués (plusieurs serveurs qui travaillent ensemble).

# Quizz

## Question 2 : Le choix d'architecture

*Si vous travaillez pour une banque et que vous devez stocker l'historique exact des transactions financières pour l'administration fiscale, devez-vous utiliser un **Data Lake** ou un **Data Warehouse** ? Pourquoi ?*

•:

Il faut utiliser un **Data Warehouse**.**Pourquoi ?** Les rapports financiers et fiscaux exigent une précision absolue, des données parfaitement propres, structurées et sans aucun doublon. Le Data Warehouse utilise le principe du *Schema-on-Write* : chaque transaction doit être validée et correspondre strictement au modèle de la banque avant d'être enregistrée. Une erreur ou un fichier corrompu n'y a pas sa place.

# Quizz

## Question 3 : L'évolution moderne

*Pourquoi les entreprises ont-elles inventé le concept de **"Data Lakehouse"** au lieu de simplement garder un Data Lake et un Data Warehouse séparés ?*

Maintenir deux systèmes séparés posait trois problèmes majeurs aux entreprises :

**Le coût :** Payer pour deux infrastructures cloud différentes coûte cher.

**La duplication :** Les données devaient souvent être copiées du Lake vers le Warehouse, créant des doublons.

**Le décalage :** Les Data Scientists travaillaient sur le Lake (données brutes) et les analystes BI sur le Warehouse (données propres), ce qui créait des conclusions parfois contradictoires.

# Quizz

**Question 4:** En Big Data, on classe les données en trois catégories : *structurées*, *semi-structurées* et *non structurées*. Donnez une définition rapide et un exemple concret pour chaque catégorie

- **Données structurées :** Elles suivent un modèle rigide et sont organisées en lignes et en colonnes.
  - ✓ *Exemple :* Une table SQL contenant les colonnes `ID_Client`, `Nom`, `Date_Achat`.
- **Données semi-structurées :** Elles n'ont pas de structure de table fixe, mais elles contiennent des balises ou des clés internes qui permettent de séparer et d'identifier les éléments.
  - ✓ *Exemple :* Un fichier JSON ou XML (très utilisés pour les API web).
- **Données non structurées :** Elles n'ont aucun modèle prédéfini. Elles représentent la majorité des données du Big Data.
  - ✓ *Exemple :* Une vidéo MP4, un fichier audio, une photo ou un email en texte libre.

# Quizz