TD 1 : Analyse des Systèmes d'Information, Architectures de Données & Big Data

Exercice 1 :

Une entreprise de e-commerce internationale gère des millions **de commandes quotidiennes**. Son infrastructure repose sur plusieurs modules :

- Un **site web** et une **application mobile**.
- Un système de **gestion** des stocks et de la logistique.
- Un service de **paiement** en ligne (interfacé avec des banques tierces).
- Un système de **recommandation** de produits basé sur l'historique de navigation.

➢ **Questions :**

1. **Ressources du SI :** Identifiez et classez au moins deux ressources **humaines**, **matérielles** et **immatérielles** composant ce système d'information.
2. **Cycle de vie de l'information :** Prenez le cas précis du processus de commande d'un client. Décrivez comment les quatre étapes fondamentales du SI sont réalisées :
   - **Collecte** **Stockage** **Traitement** **Diffusion**
3. **Interopérabilité :**
   - Pourquoi ce SI doit-il être **interopérable** avec les SI des banques et des sociétés de livraison ?
   - Quel mécanisme logiciel permet d'assurer cet échange de manière sécurisée et automatisée ?

Exercice 2 :

Une grande chaîne d'hôpitaux souhaite moderniser son système d'information **décisionnel**. Elle produit quotidiennement :

- Des données structurées : facturation, dossiers administratifs des patients, rendez-vous (issues de bases MySQL/Oracle).
- Des données semi-structurées : fichiers JSON d'objets connectés de santé (fréquence cardiaque, tension).
- Des données non structurées : imagerie médicale (radiographies, IRM), compte-rendus médicaux au format PDF ou audio.

Questions :

1. **Analyse comparative :** Complétez le tableau comparatif suivant pour guider le choix de l'hôpital :

Critère	Data Warehouse (Entrepôt de données)	Data Lake (Lac de données)
Types de données acceptées	…	…
Schéma de données	*(Schema-on-Write / Schema-on-Read)*	*(Schema-on-Write / Schema-on-Read)*
Outils associés	*…. (ex: ETL, RDBMS)*	….
Utilisateurs cibles	….	….

2. **Recommandation d'architecture :**
   - Pour l'édition des **rapports de gestion mensuels** (taux d'occupation des lits, chiffre d'affaires), quelle solution (Data Warehouse ou Data Lake) recommandez-vous et pourquoi ?
   - Pour développer un **modèle d'intelligence artificielle (Analyse Prédictive)** capable de détecter des pathologies sur des radiographies, quelle solution est la plus adaptée ?

Correction

Exercice 1 :

1. Classification des ressources du SI

- **Ressources humaines** : Équipe d'ingénieurs/développeurs, administrateurs réseau/système, livreurs, agents du service client.
- **Ressources matérielles** : Serveurs de bases de données, ordinateurs/smartphones des clients, capteurs GPS des livreurs, terminaux de paiement.
- **Ressources immatérielles** : Code source de la plateforme, base de données produits/clients, algorithme de recommandation, brevets, ….

2. Les 4 étapes du cycle de la donnée (Cas de la commande)

- **Collecte** : Saisie des articles dans le panier par le client, capture des coordonnées de livraison et des identifiants de paiement via l'interface web/mobile.
- **Stockage** : Enregistrement de la commande dans la base de données relationnelle (ex: PostgreSQL/MySQL) avec un identifiant unique et horodatage.
- **Traitement** : Vérification de la disponibilité du stock en temps réel, calcul du montant total (taxes + frais de port), déclenchement du paiement et mise à jour des stocks.
- **Diffusion** : Envoi de l'email de confirmation au client, affichage du récapitulatif sur l'écran et notification de la commande à l'entrepôt/livreur.

3. Interopérabilité et Mécanismes d'échange

- **Nécessité de l'interopérabilité** : Le **SI** de e-commerce ne peut pas tout gérer en interne (ex: transactions bancaires, logistique externe). Il doit pouvoir échanger automatiquement des données avec des SI tiers pour valider le paiement ou transmettre les ordres de livraison sans intervention humaine manuelle.
- **Mécanisme logiciel** : L'échange se fait via des **APIs (Application Programming Interfaces)** (ex: APIs RESTful) sécurisées par des jetons (OAuth2 / clés d'API) transmettant des données structurées/semi-structurées (JSON/XML).

Exercice 2 :

1. Tableau comparatif

Critère	Data Warehouse (Entrepôt de données)	Data Lake (Lac de données)
Types de données acceptées	**Données structurées** principalement (tables, schémas relationnels).	**Tous types** : structurées, semi-structurées (JSON, CSV, XML) et non structurées (images, audio, PDF).
Schéma de données	**Schema-on-Write** (les données sont nettoyées, transformées et modélisées avant d'être chargées).	**Schema-on-Read** (les données sont conservées à l'état brut ; le schéma est appliqué lors de la lecture/analyse).
Outils associés	Outils **ETL** (Extract-Transform-Load), bases de données relationnelles décisionnelles, outils de BI (PowerBI, Tableau).	Systèmes de stockage distribué (Hadoop HDFS, Amazon S3), moteurs de calcul Big Data (Spark), outils NoSQL.
Utilisateurs cibles	Décideurs, managers, analystes métiers / Business Intelligence.	Data Scientists, ingénieurs de données, statisticiens, experts en IA.

2.Recommandations d'architecture

- **Rapports de gestion mensuels Data Warehouse**
    - ***Justification*** **:** Ce besoin nécessite des chiffres **vérifiés, consolidés, reproductibles et auditables**. Le Data Warehouse offre une vue unifiée et historisée basée sur un modèle relationnel strict idéal pour le reporting institutionnel.
- **Développement d'un modèle d'IA (radiographies) Data Lake**
    - ***Justification :*** Les fichiers d'imagerie médicale sont des **données non structurées ou binaires** volumineuses. Le Data Lake permet de stocker ces données brutes sans altération pour que les algorithmes de Deep Learning puissent s'y entraîner directement.