Université Abdelmalek Essaâdi
Faculté des Sciences de Tétouan

كلية العلوم ـ تطوان
ⵜⴰⵖⵣⵓⴰⵏⵜ ⵏ ⵜⵓⵙⵙⴰⵏⵉ - ⵜⵣⴻⵓⴰ
Faculté des Sciences - Tétouan

Licence – semestre 5

Ingénierie Informatique et Développement Logicie (2IDL)

Modélisation statistique et analyse de données

Chapitre 1

Introduction au analyse de données

Année Universitaire : 2026/2007

Prof. Ouissam ZEALOUK

PLAN

- Introduction au analyse de données
- Concepts Fondamentaux de l'Analyse de Données
- L’écosystème des données
- La collecte et la préparation des données
- Visualisation de données issues du Data Mining et Communication des Résultats

Introduction

L’analyse de données joue un rôle crucial pour aider les entreprises à prendre des décisions éclairées et à répondre aux défis modernes. Qu'il s'agisse :

- Détection de la fraude par l’analyse des transactions financières : recherche de modèles pour identifier les activités frauduleuses.
- Analyse des réseaux sociaux pour comprendre la voix des clients : exploitation des publications pour obtenir un aperçu des avis des clients..
- Personnalisation des offres par l’analyse du comportement des clients : adaptation des offres commerciales en fonction des analyses des comportements clients.

Les rôles clés de l'analyse de données dans les organisations modernes sont divers. Ces experts, avec leurs compétences spécifiques, travaillent ensemble pour extraire des informations précieuses, permettant aux entreprises de prendre des décisions éclairées et de rester compétitives.

- Ingénieurs de données
- Analystes de données
- Scientifiques des données
- Analystes d'affaires
- Analystes de la Business Intelligence (BI)

❑ Ingénieur de données (data engineer)

Développement et gestion des architectures de données

- Création d'architectures de données robustes
- Gestion des référentiels de données

Extraction et organisation des données

- Intégration de données à partir de différentes sources
- Préparation et transformation des données pour les rendre utilisables

Compétences requises

- Programmation
- Connaissance des systèmes et des architectures technologiques
- Compréhension des bases de données relationnelles et non relationnelles

❑ Analyste de données (data analyst)

Traduction des données en informations compréhensibles

- Simplification des données et des chiffres pour une meilleure compréhension

Analyse et visualisation des données

- Nettoyage des données et identification des corrélations
- Application de méthodes statistiques et création de visualisations

Compétences requises

- Feuilles de calcul et rédaction de requêtes
- Utilisation d'outils statistiques et de programmation
- Compétences en analyse et en narration

❑ Scientifique des données (Data Scientist)

Analyse des données pour obtenir des informations exploitables

- Utilisation de modèles d'apprentissage automatique et profond
- Création de modèles prédictifs basés sur les données passées

Questions prédictives

- Estimation du nombre de nouveaux abonnés sur les médias sociaux
- Prédiction des pertes de clients face à la concurrence
- Identification des transactions financières inhabituelles

Compétences requises

- Mathématiques et statistiques
- Langages de programmation et bases de données
- Connaissances de domaine

❑ Analyste d'affaires

Examen des implications pour l'entreprise

- Cela consiste à analyser les données recueillies afin de déterminer comment elles peuvent influencer les opérations et les stratégies de l'entreprise. L'objectif est de recommander des actions stratégiques basées sur les résultats de cette analyse.
- Par exemple, si les données indiquent une baisse de la satisfaction client, l'entreprise pourrait envisager d'améliorer son service à la clientèle ou de revoir ses produits.

Collaboration avec les analystes de données et les scientifiques des données

- Cette collaboration réunit des experts en analyse de données pour soutenir la prise de décision.Les informations obtenues permettent de baser les choix sur des faits plutôt que sur des intuitions. Elles favorisent ainsi des décisions plus efficaces en marketing, développement de produits et gestion des opérations.

❑ Analyste BI

Focalisation sur les forces du marché et influences extérieures :

- Cela consiste à analyser les tendances du marché et les facteurs externes, comme la concurrence et l'économie, pour mieux comprendre le contexte dans lequel l'entreprise évolue.

Organisation et surveillance des données :

- Cette étape implique l'exploration et la structuration des données afin d'extraire des informations exploitables, permettant d'identifier des modèles et des insights utiles pour la prise de décision.

Fourniture de solutions intelligentes :

- Cela se réfère à l'utilisation d'analyses approfondies pour proposer des solutions stratégiques qui améliorent les performances de l'entreprise, en optimisant les processus et en augmentant l'efficacité.

❑ Définition

L’analyse des données consiste à collecter, nettoyer, analyser et interpréter les informations afin d’identifier des schémas et des corrélations utiles. Elle permet aux entreprises de mieux comprendre leurs performances passées, d’orienter leurs décisions futures et de valider leurs plans d’action. Ce processus contribue ainsi à une meilleure allocation des ressources, à un gain de temps et à une amélioration globale de l’efficacité et du succès organisationnel.

❑ Types d'analyse des données

Il existe quatre principaux types d'analyse des données, chacun ayant un objectif et une place différents dans le processus d'analyse des données :

- Analyse descriptive
- Analyse diagnostique
- Analyse prédictive
- Analyse prescriptive

❑ Types d'analyse des données

❑ Analyse descriptive (Descriptive Analytics)



Ce qui s'est passé ?

- Résumer les données passées pour comprendre ce qui s'est passé.
- Fournir des informations essentielles sur les événements passés aux parties prenantes.

Exemple :

Analyser les tendances des flux de trésorerie permet de comprendre les mouvements d'argent au sein de l'entreprise, en examinant les entrées et les sorties de fonds. Cela aide à évaluer la santé financière, à anticiper les besoins de liquidités et à prendre des décisions éclairées sur les investissements et les dépenses.

❑ Types d'analyse des données

❑ Analyse diagnostique (Diagnostic Analytics)



Pourquoi est-ce arrivé ?

- Explorer les raisons derrière les événements passés pour comprendre pourquoi ils se sont produits.
- Utiliser les informations de l'analyse descriptive pour approfondir l'examen des causes sous-jacente.

Exemple :

Analyser une hausse des ventes dans une région spécifique sans changements de marketing pour identifier les facteurs cachés.

❑ Types d'analyse des données

❑ Analyse prédictive (Predictive Analytics)



Que va-t-il se passer ensuite ?

- Prévoir les événements futurs basés sur les données historiques et les tendances.
- Aider les organisations à anticiper les changements et à se préparer pour l'avenir

Exemple :

Prévisions de ventes pour planifier les stocks et les ressources en conséquences.

❑ Types d'analyse des données

❑ Analyse prescriptive (Prescriptive Analytics)



que faut-il faire à ce sujet ?

- Recommander des actions basées sur l'analyse des décisions et des événements passés.
- Aider les organisations à déterminer la meilleure marche à suivre pour atteindre leurs objectifs..

Exemple :

Compagnies aériennes ajustant automatiquement les prix des billets en fonction de la demande des clients, des prix du carburant, des conditions météorologiques et du trafic.

.

❑ Etapes d'analyse des données

L'analyse des données suit un processus systématique pour garantir des résultats précis et utiles.

Etape 1 : Comprendre le problème et le résultat souhaité

- **Objectif :**
  - Définir clairement le problème à résoudre.
  - Identifier le résultat souhaité.
- **Importance :**
  - Comprendre où vous en êtes et où vous voulez aller.

Exemple :

Déterminer le problème de baisse des ventes dans une région spécifique et viser une augmentation des ventes de 10% dans cette région.

❑ Etapes d'analyse des données

Etape 2 : Définition d'une mesure claire

- **Objectif :**
  - Décider de ce qui sera mesuré et comment cela sera mesuré.
- **Étapes :**
  - Identifier les métriques clés (ex. : nombre de produits vendus).
  - Définir la période de mesure (ex. : trimestre, saison de festival).

Exemple :

Mesurer le nombre de produits X vendus pendant une saison de festival

❑ Etapes d'analyse des données

Etape 3 : Collecte des données

- **Objectif :**
  - Identifier les données nécessaires et leurs sources.
  - Choisir les outils appropriés pour la collecte des données.
- **Étapes :**
  - Déterminer les sources de données (ex. : bases de données internes, enquêtes).
  - Utiliser les outils de collecte de données (ex. : logiciels d'analyse, scripts d'extraction de données).

Exemple :

Collecter des données de vente à partir de systèmes de points de vente (POS).

❑ Etapes d'analyse des données

Etape 4 : Nettoyage des données

- **Objectif :**
  - Résoudre les problèmes de qualité des données pour garantir leur exactitude.
- **Étapes :**
  - Identifier et corriger les valeurs manquantes ou aberrantes.
  - Normaliser les données provenant de différentes sources.

Exemple :

Corriger les données démographiques où l'âge d'un client est de 250 ans, ce qui est une valeur aberrante.

❑ Etapes d'analyse des données

Etape 5 : Analyse et exploration des données

- **Objectif :**
  - Extraire et analyser les données sous différents angles.
- **Étapes :**
  - Manipuler les données pour comprendre les tendances, identifier les corrélations et trouver des modèles.
  - Utiliser des techniques d'analyse exploratoire des données (EDA).

Exemple :

Analyser les ventes de produits pour identifier des modèles saisonniers.

❑ Etapes d'analyse des données

Etape 6 : Interprétation des résultats

- **Objectif :**
  - Évaluer et interpréter les résultats de l'analyse.
- **Étapes :**
  - Vérifier la robustesse de l'analyse contre les objections potentielles.
  - Identifier les limites de l'analyse et les conditions dans lesquelles les résultats peuvent ne pas être vérifiés.

Exemple :

Évaluer si l'augmentation des ventes est due à une campagne marketing spécifique ou à d'autres facteurs.

❑ Etapes d'analyse des données

Etape 7 : Présentation des résultats

- **Objectif :**
  - Communiquer clairement et efficacement les conclusions de l'analyse.
  - **Méthodes :**
  - Utiliser des rapports, des tableaux de bord, des graphiques, des cartes et des études de cas.
- **Importance** :
  - L'objectif de toute analyse est d'influencer la prise de décision.

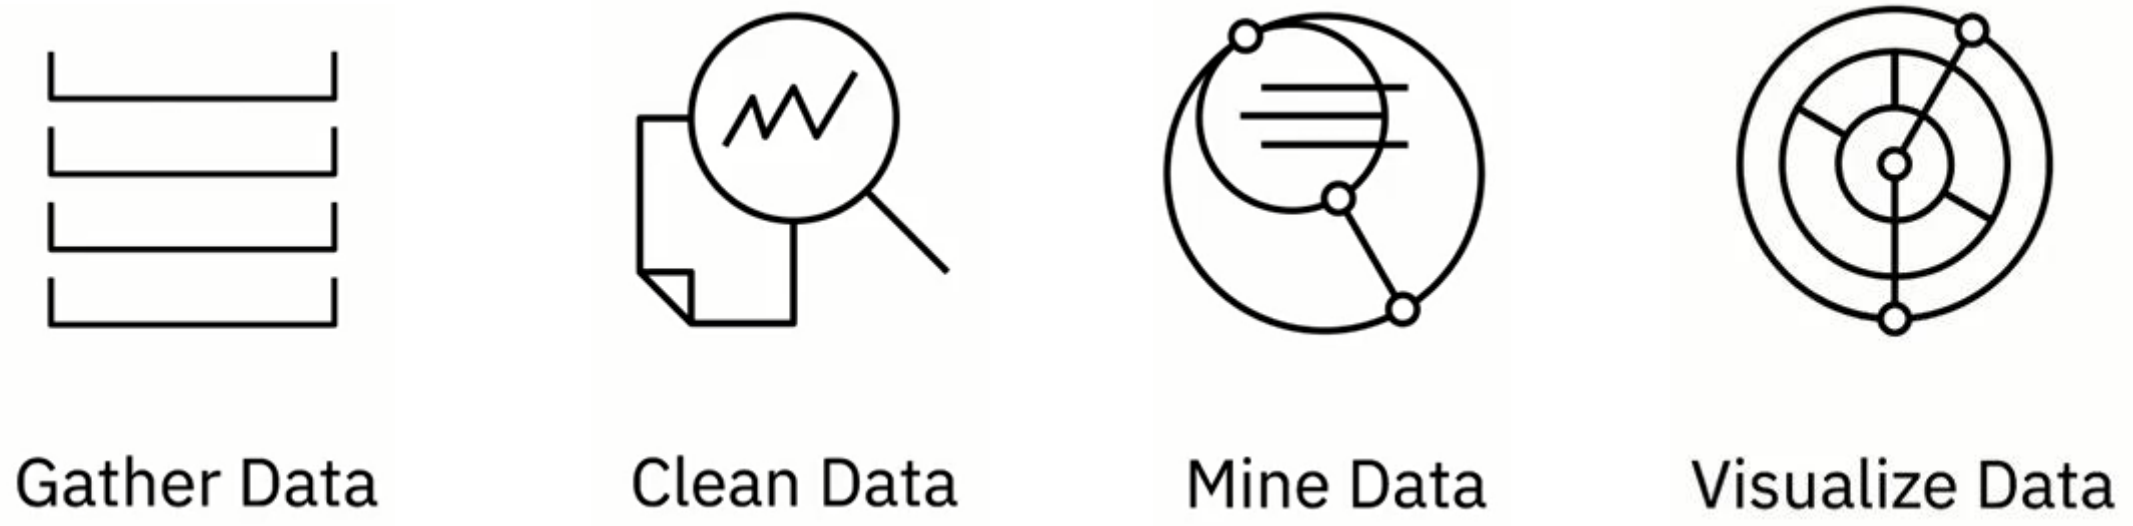
Exemple :

Présenter un tableau de bord interactif montrant l'augmentation des ventes par région et par période.

❑ Perspectives professionnelles

Différents experts en données expliquent leurs propres interprétations et points de vue sur ce qu'est l'analyse des données, en mettant en avant la diversité des compréhensions de ce concept parmi les professionnels.

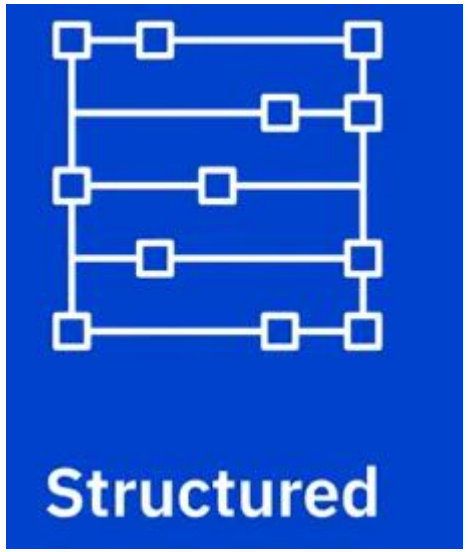
L'écosystème d'un analyste de données comprend l'infrastructure, les logiciels, les outils, les cadres et les processus utilisés pour collecter, nettoyer, analyser, extraire et visualiser les données.

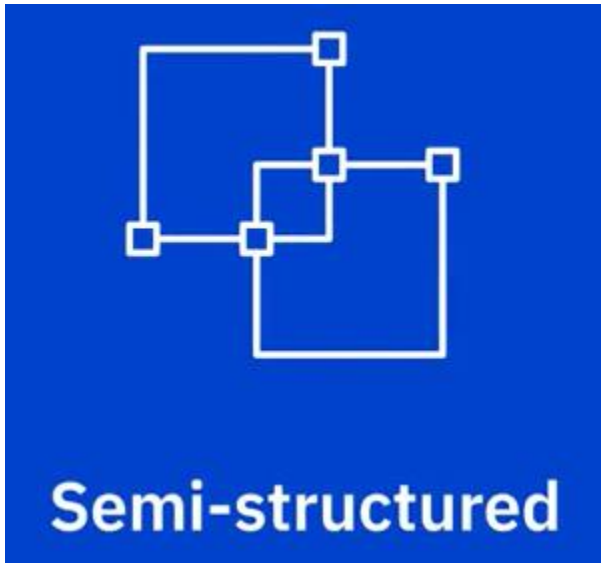


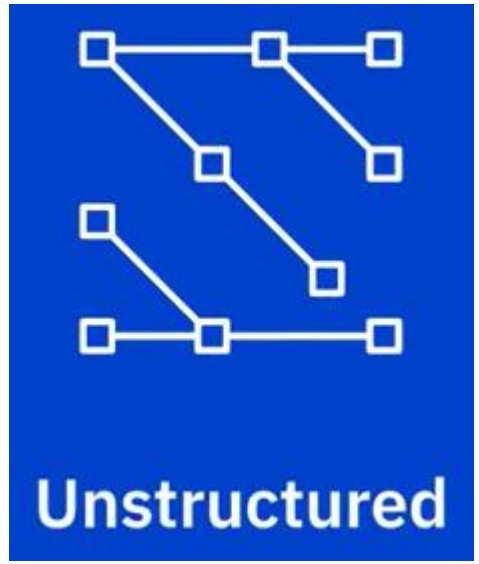
- **Données**

Les données sont des informations brutes, souvent non organisées, qui nécessitent un traitement pour leur donner un sens. Elles peuvent être classées en fonction de leur structure et comprennent divers éléments comme des faits, des observations, des chiffres, des symboles, et des images.

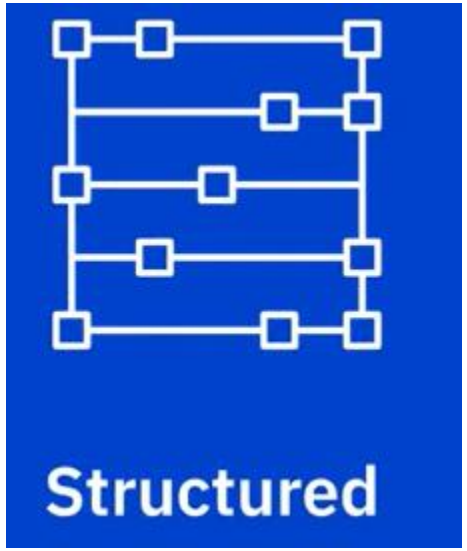
Les données peuvent être classées comme structurées, semi-structurées ou non structurées.







Données structurées

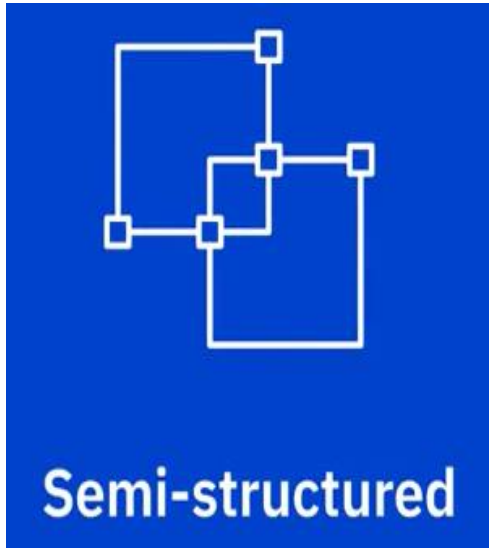


Définition : Les données structurées suivent un format rigide et peuvent être organisées de manière systématique en lignes et en colonnes.

Exemples : Bases de données, feuilles de calcul.

Caractéristiques : Facilement consultables et analysables grâce à leur organisation claire.

Données semi-structurées

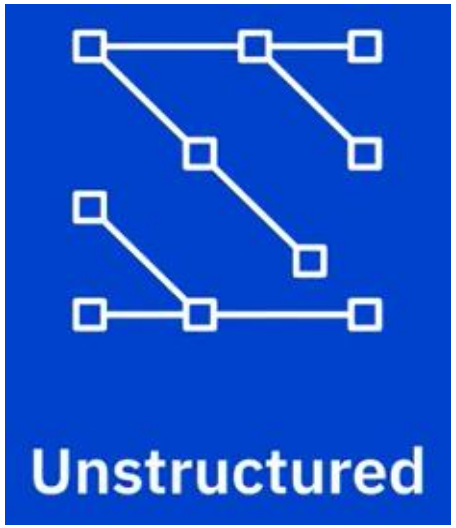


Définition : Les données semi-structurées sont un mélange de données structurées et non structurées, avec des caractéristiques cohérentes mais sans structure rigide.

Exemples : Courriels, où des éléments comme le nom de l'expéditeur et du destinataire sont structurés, mais le contenu reste non structuré.

Caractéristiques : Nécessite des outils spécifiques pour extraire et analyser les différentes parties.

Données non structurées



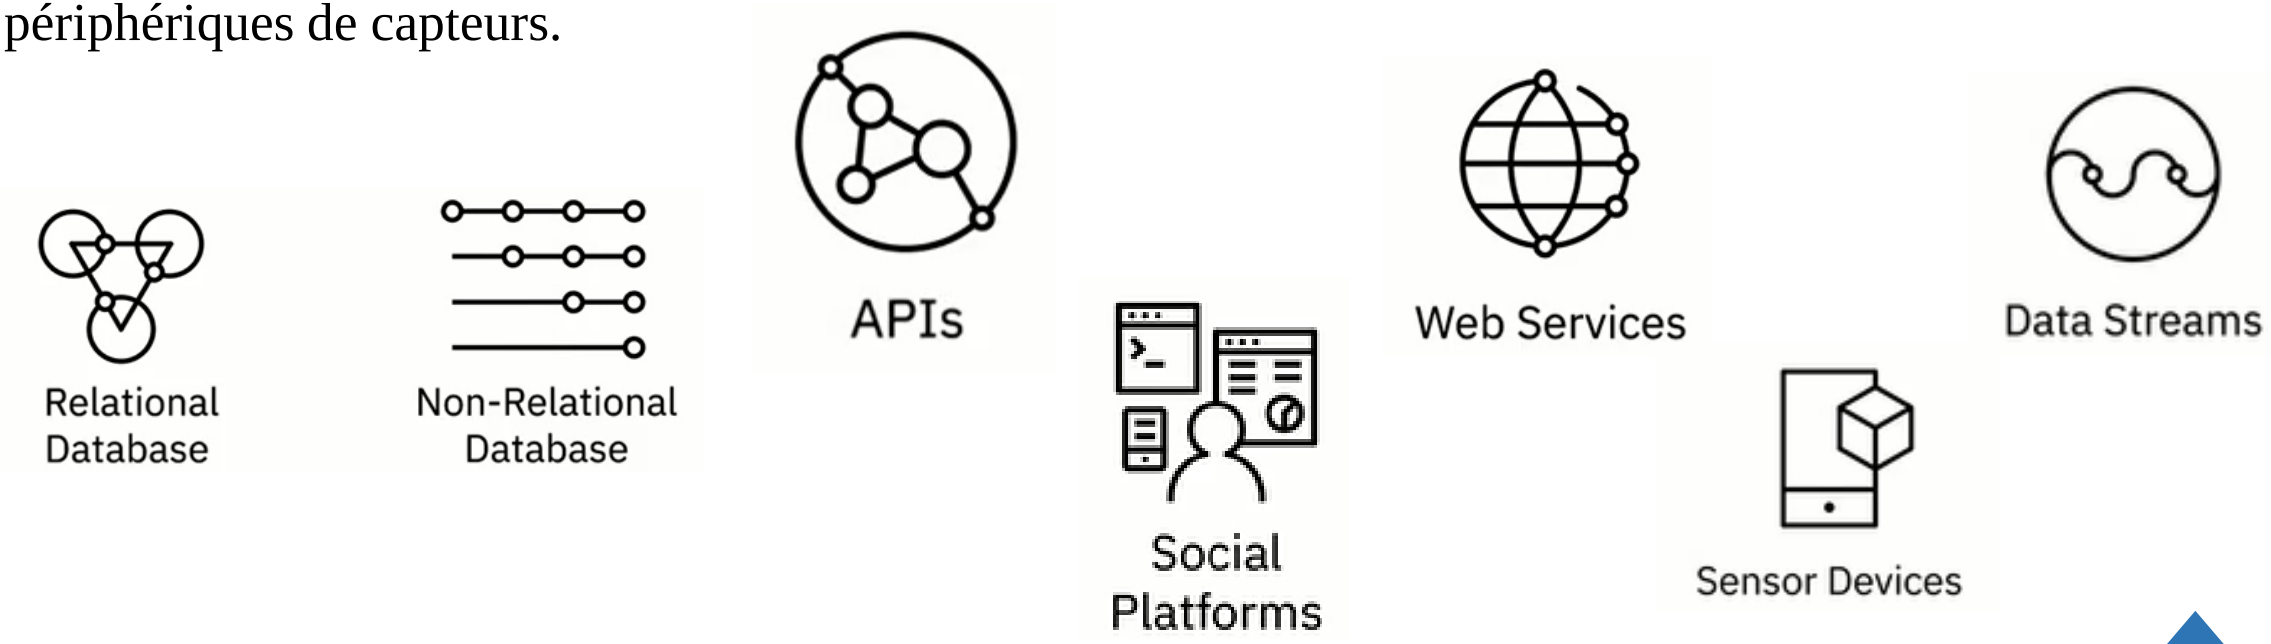
Définition : Les données non structurées sont des informations complexes et qualitatives qui ne peuvent pas être facilement organisées en lignes et en colonnes**.**

Exemples : Photos, vidéos, fichiers texte, PDF, contenu des médias sociaux.

Caractéristiques : Requiert des techniques avancées pour être traitées et analysées, comme l'utilisation de l'intelligence artificielle ou de l'apprentissage automatique.

Types de formats de fichiers

Les données sont également disponibles dans une grande variété de formats de fichiers collectés à partir d'une variété de sources de données, allant des bases de données relationnelles et non relationnelles aux API, aux services Web, aux flux de données, aux plateformes sociales et aux périphériques de capteurs.



Formats de fichiers standard

- Formats de fichiers texte délimités
- Microsoft Excel Open XML (XLSX)
- Extensible Markup Language (XML)
- Portable Document Format (PDF)
- JavaScript Object Notation (JSON)

- **Formats de fichiers texte délimités**

Les fichiers texte délimités stockent des données sous forme de texte, où chaque ligne contient des valeurs séparées par un délimiteur; où un délimiteur est une séquence de caractères qui sépare les valeurs dans une ligne de texte (**Virgule** (,) **Tabulation** (Tab) **Deux-points** (:) **Barre verticale** (|) **Espace** ( )).



CSV (Comma-Separated Values)
Les valeurs sont séparées par des virgules.



TSV (Tab-Separated Values)
Les valeurs sont séparées par des tabulations..

Remarque : Les fichiers TSV constituent une alternative aux CSV lorsque les données contiennent des virgules, car ils utilisent la tabulation comme séparateur au lieu de la virgule.

- **Formats de fichiers texte délimités**






```
Manufacturer, Model, Sales_in_thousands, __year_resale_value, Vehicle_type, Price_in_thousands
Acura, Integra, 16.919, 16.36, Passenger, 21.5
Acura, TL, 39.384, 19.875, Passenger, 28.4
Acura, CL, 14.114, 18.225, Passenger, 14
Acura, RL, 8.588, 29.725, Passenger, 42
Audi, A4, 20.397, 22.255, Passenger, 23.99
Audi, A6, 18.78, 23.555, Passenger, 33.95
Audi, A8, 1.38, 39, Passenger, 62
BMW, 323i, 19.747, Passenger, 26.99
BMW, 328i, 9.231, 28.675, Passenger, 33.4
BMW, 528i, 17.527, 36.125, Passenger, 38.9
Buick, Century, 91.561, 12.475, Passenger, 21.975
```

Manufacturer	Model	Sales_in_thousands		__year_resale_value
Acura	Integra	16.919	16.36 Passenger	21.5
Acura	TL	39.384	19.875 Passenger	28.4
Acura	CL	14.114	18.225 Passenger	
Acura	RL	8.588	29.725 Passenger	42
Audi	A4	20.397	22.255 Passenger	23.99
Audi	A6	18.78	23.555 Passenger	33.95
Audi	A8	1.38	39 Passenger	62
BMW	323i	19.747	Passenger	26.99
BMW	328i	9.231	28.675 Passenger	33.4
BMW	528i	17.527	36.125 Passenger	38.9
Buick	Century	91.561	12.475 Passenger	21.975

Lignes : Chaque ligne du fichier représente un enregistrement.

En-tête : La première ligne fonctionne souvent comme un en-tête de colonne.

Types de colonnes : Chaque colonne peut contenir un type de données différent (date, chaîne, entier).

- **Formats de fichiers texte délimités**

Avantages des Fichiers Texte Délimités

- ❑ Flexibilité : Autorise des valeurs de champ de n'importe quelle longueur.
- ❑ Standardisation : Considérés comme un format standard pour un schéma d'information simple.
- ❑ Compatibilité : Peuvent être traités par presque toutes les applications existantes.

- **JavaScript Object Notation (JSON)**

- **Standard ouvert basé sur le texte** pour transmettre des données structurées sur le Web.
- **Indépendant de la langue** : Lisible dans n'importe quel langage de programmation.
- **Facile à utiliser** et compatible avec un **large éventail de navigateurs**.
- Idéal pour partager des données de **toute taille et type**, y compris **audio et vidéo**.
- **Utilisation courante** : De nombreuses **API et services Web** renvoient des données en JSON.


```
{
    "Employee": [
        {
          "id":"1",
          "Manufacturer": "Audi",
          "Model": "Integra",
        },
        {
          "id":"2",
          "Manufacturer": "Buick",
          "Model": "LeSabre",
        },
        {
          "id":"3",
          "Manufacturer": "Cadillac",
          "Model": "Escalade",
        }
    ]
}
```

- **Les sources de données**

Avec l'essor du numérique, les sources de données sont aujourd'hui plus dynamiques et variées. Les entreprises modernes utilisent ces données pour identifier de nouvelles opportunités et orienter leurs stratégies. De nombreuses sources de données sont à leur disposition, allant des **bases de données relationnelles** aux **API**, en passant par le **web scraping** et les **flux de données**. Chacune de ces sources joue un rôle crucial dans l'analyse pour transformer les données brutes en informations exploitables.

Les sources de données : Bases de Données Relationnelles

- **Définition :**
  - Stockent des données de manière **structurée**, organisées en **tables**, **lignes**, et **colonnes**.
  - **Relationnelles** signifie que les données dans différentes tables peuvent être **liées entre elles** par des relations (ex. : clé primaire et clé étrangère).
- **Exemples de bases de données relationnelles :**
  - SQL Server, Oracle, MySQL, IBM DB2.

Les sources de données : Bases de Données Relationnelles

- **Utilisations courantes :**
  - **Systèmes de gestion des transactions** pour suivre les achats, les ventes et les paiements.
  - **Systèmes de gestion de la relation client (CRM)** pour analyser le comportement client et prévoir les ventes.
- **Avantages :**
  - **Intégrité des données** : Assurent que les données sont exactes et cohérentes.
  - **Capacité de requête** : Les requêtes SQL permettent de filtrer, regrouper et extraire des informations précises.

Les sources de données : Bases de Données non Relationnelles

- **Définition :**
  - Aussi appelées **NoSQL**, elles stockent des données de manière plus flexible (ex : documents JSON).
  - Idéales pour **gérer des données massives** et **non structurées**.
- **Exemples :**
  - **MongoDB** (base de données de documents), **Cassandra** (large-scale data), **Redis** (base de données clé-valeur).
- **Avantages :**
  - **Scalabilité horizontale** : Adaptées aux systèmes qui doivent évoluer pour stocker de grandes quantités de données.
  - **Flexibilité de schéma** : Pas de schéma rigide, ce qui permet d’adapter facilement la structure des données.

Les sources de données : Fichiers Plats et Formats de Données

- **Fichiers Plats :**
  - Stockent des données sous forme de texte brut, chaque enregistrement étant une ligne et chaque valeur séparée par un **délimiteur** (ex : virgule, point-virgule).
  - **Exemples** : **CSV (Comma-Separated Values)**, **TSV (Tab-Separated Values)**.

- **Utilisations :**
  - **Échange simple de données** entre systèmes hétérogènes.
  - Facile à lire par les programmes et les scripts.

Les sources de données : Fichiers Plats et Formats de Données

- **Avantages :**
  - **Simplicité** : Format simple à manipuler et lire.
  - **Large compatibilité** : Les fichiers CSV peuvent être ouverts par des feuilles de calcul comme **Excel** ou **Google Sheets**.

- **Limites :**
  - **Pas de structure complexe** : Contrairement aux bases de données, les fichiers plats ne supportent pas les relations entre les enregistrements.
  - **Difficulté de mise à jour** : Difficiles à manipuler pour les mises à jour fréquentes.

Les sources de données : Jeux de données XML

- **XML (Extensible Markup Language) :**
  - Langage de balisage qui utilise des **balises personnalisées** pour organiser les données.
  - Les fichiers XML peuvent représenter des **structures hiérarchiques complexes**.

- **Utilisations courantes :**
  - **Données non structurées** comme les réponses à des enquêtes ou les relevés bancaires.
  - Transmission de **données entre systèmes** via des services Web.

Les sources de données : Jeux de données XML

- **Avantages :**
  - **Portabilité** : Les fichiers XML peuvent être lus et analysés par différents systèmes et plateformes.
  - **Lisibilité humaine** : Bien qu’il soit structuré pour les machines, le XML reste lisible pour les humains.

- **Limites :**
  - **Verbosité** : Les fichiers XML peuvent être très volumineux en raison de la répétition des balises.
  - **Complexité de parsing :** Plus complexe à analyser comparé à des formats comme JSON

Les sources de données : API et services Web

- **API (Application Programming Interface) :**
  - Fournit une interface pour accéder aux fonctionnalités ou aux données d'une application.
  - Permet aux systèmes de **communiquer entre eux**.
- **Services Web :**
  - Un type d'API accessible via le **protocole HTTP**.
  - Peut renvoyer des données sous différents formats : **JSON**, **XML**, **HTML**, etc.
- **Exemples populaires d'API :**
  - **Twitter, Facebook** pour l'analyse de sentiments à partir de tweets et de publications.
  - **API boursières** pour les données financières en temps réel.
  - **API de validation de données** pour le nettoyage de bases de données (ex. : vérification de code postal).

Les sources de données : API et services Web

- **Avantages :**
  - **Accès en temps réel** aux données.
  - **Intégration** entre applications et systèmes.
- **Limites :**
  - **Débit limité** : Certaines API imposent des quotas d'utilisation.
  - **Dépendance : Les modifications de l'API peuvent nécessiter des adaptations.**

Les sources de données : Web scraping

- **Définition :**
  - Extraction de données depuis des sites web en utilisant des **scripts automatisés**.
  - Permet de **collecter des informations non structurées**.
- **Utilisations courantes :**
  - **Comparaison de prix** sur les sites de commerce électronique.
  - **Génération de pistes de vente** à partir de répertoires publics.
  - **Extraction de contenu** pour l’entraînement de modèles d'apprentissage automatique.
- **Outils de scraping :**
  - **BeautifulSoup** : Analyse les pages HTML.
  - **Scrapy** : Framework de scraping pour les projets à grande échelle.
  - **Selenium** : Automatisation des interactions avec les navigateurs.

Les sources de données : Web scraping

- **Avantages :**
  - **Accès à des données non disponibles via API**.
  - **Flexibilité** pour extraire des données spécifiques.
- **Limites :**
  - **Légalité** : Certains sites interdisent le scraping dans leurs conditions d'utilisation.
  - **Maintenance** : Les changements de structure des sites peuvent casser les scripts.

Les sources de données : Flux de données

- **Définition :**
  - Les flux de données sont des informations générées en continu par divers appareils et systèmes, comme les capteurs IoT, les applications, ou les services en ligne.
- **Exemples :**
  - **Un capteur de température** dans une usine envoie régulièrement des données pour suivre les conditions en temps réel. Ces données sont souvent horodatées (elles incluent l’heure et la date de génération) et géo-étiquetées (elles indiquent l’emplacement de leur origine), ce qui permet de suivre précisément leur source et de les analyser en fonction du lieu et du moment.
  - **Tickers boursiers pour le trading en temps réel.**
  - **Données GPS** des véhicules pour la logistique.
  - **Flux de médias sociaux** pour l’analyse de tendances.
  - **Capteurs IoT** pour la maintenance prédictive.

Les sources de données : Flux de données

- **Applications pour le traitement des flux :**
  - **Apache Kafka** : Gestion de flux de données à haute vélocité.
  - **Apache Spark Streaming** : Analyse en temps réel.
  - **Apache Storm** : Traitement des données en continu.
- **Avantages :**
  - **Analyse en temps réel** pour une prise de décision rapide.
  - **Gestion de gros volumes de données**.
- **Limites :**
  - **Complexité** de mise en œuvre.
  - **Besoin de compétences spécialisées** pour la gestion des flux.

Les sources de données : Flux RSS

- **Définition :**
  - **Really Simple Syndication** : Permet de recevoir des mises à jour de contenu depuis des sites.
- **Utilisations :**
  - Suivre les **nouvelles** ou les **articles de blogs**.
  - **Surveillance des forums** pour des sujets spécifiques.
- **Avantages :**
  - **Automatisation** de la collecte des mises à jour.
  - Facilité d’intégration avec des **lecteurs de flux** pour surveiller les changements.
- **Limites :**
  - **Dépendant du site** : Si le site ne publie pas de flux RSS, impossible de le suivre.

❑ Langages de Programmation

- **Python :**
  - Langage open source, facile à apprendre, adapté aux débutants.
- **Avantages :**
  - Simplicité, vaste communauté, nombreuses bibliothèques (Numpy, Pandas, Matplotlib, etc.).
  - Supporte plusieurs paradigmes de programmation.

❑ Langages de Programmation

- **R :**
  - Langage et environnement pour l'analyse de données, la visualisation, et les statistiques.
- **Avantages :**
  - Open source, hautement extensible, gestion des données structurées/non structurées.
  - Bibliothèques pour des visualisations esthétiques (Ggplot2, Plotly).
- **Java :**
  - Langage orienté objet, utilisé dans les projets de Big Data (Hadoop, Hive, Spark).
- **Avantages :**
  - Indépendant de la plateforme, adapté aux projets à vitesse critique.

❑ Langages pour les Professionnels des Données : Scripts Shell

- **Unix/Linux Shell :**
  - Programme informatique pour les tâches répétitives via des commandes UNIX.
- **Utilisations typiques :**
  - Manipulation de fichiers, administration système, exécution de sauvegardes, etc.
- **PowerShell :**
  - Outil d'automatisation multiplateforme de Microsoft.
- **Avantages :**
  - Basé sur des objets, filtrage et manipulation via pipeline de données.
  - Idéal pour l'exploration de données, création de graphiques, tableaux de bord interactifs.

Un référentiel de données est un système qui collecte, organise et stocke les données afin de les rendre facilement exploitables pour les besoins commerciaux, de reporting et d’analyse.

- **Types de référentiels :**
  - **Bases de données** (relationnelles et non relationnelles)
  - **Entrepôts de données** et **Data Marts**
  - **Data Lakes**
  - **Big Data Stores**

❑ Bases de Données Relationnelles

- **Structure :** Organisation en **tables**, avec des **lignes** (enregistrements) et **colonnes** (attributs).
- **SGBDR (Système de Gestion de Bases de Données Relationnelles) :** Programme permettant de créer, gérer et interroger les bases de données via **SQL**.
- **Exemples :** SQL Server, Oracle, MySQL, PostgreSQL, IBM DB2.
- **Avantages :**
  - **Conformité ACID** pour la fiabilité des transactions.
  - **Liens entre tables** pour des analyses complexes.
  - **Sécurité et contrôle d’accès** pour une gestion centralisée des données.

❑ Bases de Données Non Relationnelles (NoSQL)

- **Conception :** Flexibilité et scalabilité pour stocker des données sans schéma fixe.
- **Types courants :**
  - **Clé-valeur** (ex. : Redis, DynamoDB)
  - **Basé sur des documents** (ex. : MongoDB, CouchDB)
  - **Basé sur des colonnes** (ex. : Cassandra, HBase)
  - **Basé sur des graphes** (ex. : Neo4j, CosmosDB)
- **Avantages :**
  - **Scalabilité horizontale** pour les applications à haute demande.
  - **Adaptation rapide** aux nouvelles structures de données.
- **Limites :** Moins adapté pour les transactions complexes et les systèmes nécessitant la conformité ACID.

❑ Entrepôts de Données (Data Warehouses) et Data Marts

- **Entrepôts de Données (Data Warehouses):**
  - Centralisent les données traitées et structurées pour l’analyse.
  - Processus ETL : Extraction, Transformation, Chargement des données pour une vue consolidée.
  - **Exemples :** Amazon Redshift, Google BigQuery, Snowflake.
- **Data Marts :**
  - Sous-ensembles d’un entrepôt de données, ciblant des départements spécifiques (ex : vente, finance).
  - **Avantages :** Accès rapide aux données pertinentes pour les utilisateurs spécifiques.

❑ Data Lakes

- **Définition :** Réservoir de données qui stocke les données brutes dans leur format natif (structurées, semi-structurées, non structurées).
- **Utilisations :**
  - Idéal pour les analyses prédictives et avancées.
  - Sert de zone de transit pour les données destinées à un entrepôt de données.
- **Avantages :**
  - **Flexibilité** pour stocker de grandes quantités de données sans transformation préalable.
  - **Évolutivité** pour répondre aux besoins de stockage croissants..

❑ Big Data Stores et Traitement Distribué

- **Définition :** Infrastructure pour stocker et traiter de grands volumes de données sur des clusters de serveurs.
- **Technologies clés :**
  - **Hadoop** : Framework pour le stockage distribué avec **HDFS** et traitement avec **MapReduce**.
  - **Apache Spark** : Analyse de données en mémoire pour le traitement **en temps réel**.
  - **Hive** : Entrepôt de données pour exécuter des requêtes SQL sur des données stockées dans Hadoop.
- **Avantages :**
  - **Tolérance aux pannes** grâce à la réplication des données.
  - **Scalabilité horizontale** pour gérer les volumes croissants de données.

❑ Comparaison Bases de Données Relationnelles vs NoSQL

- **Bases de Données Relationnelles (SGBDR) :**
  - **Structure rigide**, relations entre les tables, **supporte SQL**.
  - Adaptées aux **transactions complexes** et à la **conformité ACID**.
- **Bases de Données NoSQL :**
  - **Schéma flexible** pour une adaptation rapide.
  - Scalabilité et performance pour le **Big Data** et les **applications modernes**.
- **Choix selon les besoins :**
  - **SGBDR** pour la cohérence et la fiabilité.
  - **NoSQL** pour la flexibilité et les environnements à forte croissance de données.

❑ ETL et Pipelines de Données

- **Processus ETL :**
  - **Extraction** : Récupération des données depuis différentes sources.
  - **Transformation** : Nettoyage et formatage des données.
  - **Chargement** : Stockage des données transformées dans le référentiel.
- **Pipelines de Données :**
  - Enchaînent plusieurs étapes de transformation et de chargement.
  - **Adaptés au traitement par lots** et au **streaming**.
  - Outils : **Apache Kafka, Apache Beam** pour la gestion de flux de données en continu.

❑ Les 5 V du Big Data

- **Volume :** Quantité massive de données générées (ex : 2,5 quintillions d'octets par jour).
- **Vélocité :** Vitesse à laquelle les données sont générées et analysées (ex : données en temps réel de capteurs IoT).
- **Variété :** Diversité des types de données (structurées, non structurées, semi-structurées).
- **Véracité :** Qualité et fiabilité des données (ex : différencier les données vraies des fausses).
- **Valeur :** Capacité à transformer les données en informations exploitables (ex : analyse prédictive).

L'introduction à la collecte et préparation des données permet de mieux comprendre l'importance d'identifier clairement le problème à résoudre et les objectifs à atteindre. Ce processus inclut la définition des données à collecter, la méthode de collecte et les exigences de qualité, de sécurité et de conformité. Une bonne préparation assure une base solide pour des analyses fiables et des décisions éclairées.

- **Compréhension du problème et de l'objectif**
  - Définir clairement où vous êtes actuellement et où vous voulez aller.
  - Identifier ce qui sera mesuré et comment cela sera mesuré.

Exemple : Une entreprise de commerce électronique souhaite augmenter sa part de marché. Pour cela, elle devra définir des indicateurs tels que le taux de conversion des campagnes publicitaires (par exemple, combien de visiteurs deviennent des acheteurs), le taux d'acquisition de nouveaux clients et le taux de fidélisation des clients existants.

- **Identification des données nécessaires**

- **Étape suivante** : Identifier les données dont vous avez besoin pour atteindre vos objectifs.

  - **Informations spécifiques** : Décider quelles informations sont nécessaires.

    - **Exemple :** Pour augmenter la satisfaction client, des données sur les retours clients (comme les commentaires des clients après un achat), les temps de réponse du service client et la qualité du service fourni (mesurée par des enquêtes de satisfaction) sont nécessaires pour comprendre les points à améliorer.

- **Identification des données nécessaires**
  - **Sources possibles : Identifier les sources potentielles des données.**
    - **Exemple :** Les sources peuvent inclure des sondages clients (envoyés après une interaction avec le service), des commentaires sur les réseaux sociaux (récoltés à partir de plateformes comme Facebook et Twitter), et des données internes du CRM (suivi des plaintes, historique des interactions).

- **Exemple pratique** : Une entreprise de vente de produits de consommation souhaite cibler ses campagnes marketing en fonction des groupes d'âge les plus susceptibles d'acheter. Les données nécessaires peuvent inclure l'âge des clients, leurs préférences d'achat et leur engagement sur les réseaux sociaux.

- **Cas pratique : données à collecter**
  - **Objectif** : Créer des campagnes marketing ciblées selon le groupe d'âge.
  - **Données à collecter :**
    - **Profil client : âge, profession, revenu, état matrimonial.**
      - Ces informations permettent de segmenter les clients et de cibler les campagnes en fonction des caractéristiques démographiques les plus pertinentes.
    - **Historique des achats : fréquences et montants des achats.**
      - Connaître la fréquence et le montant des achats aide à identifier les clients réguliers et à élaborer des offres spéciales pour les fidéliser.
    - **Localisation : pour cibler des publicités géographiquement.**
      - Adapter les campagnes publicitaires en fonction de la région permet de maximiser leur pertinence, par exemple en promouvant des produits spécifiques à certaines saisons ou événements locaux.

Plan de collecte de données

- **Définir un plan de collecte**
  - **Calendrier** : Établir un calendrier de collecte, qu'il soit continu ou pour une période définie.
    - **Exemple :** Collecter les données de visites de site web en temps réel permet d'analyser immédiatement les comportements des utilisateurs et d'ajuster les stratégies de marketing en conséquence, alors que la collecte des données d'une campagne marketing spécifique peut se faire pendant une durée limitée afin d'en évaluer l'impact.

Plan de collecte de données

- **Volume de données** : Déterminer la quantité de données suffisante pour une analyse crédible (ex. : tranche d'âge spécifique).
  - **Exemple :** Pour analyser les comportements d'achat des jeunes adultes, il est important de disposer d'un échantillon d'au moins 10 000 clients âgés de 21 à 30 ans afin d'assurer une représentativité statistique.

- **Dépendances et risques :** Identifier les dépendances, les risques, et élaborer des stratégies d'atténuation.
  - **Exemple :** Si une grande partie des données provient de sondages, un risque peut être que peu de clients répondent. Pour l'atténuer, on peut prévoir des incitations pour encourager la participation.

Méthodes de collecte de données

- **Méthodes** : Déterminer comment collecter les données à partir des sources identifiées.
  - **Exemples :**
  - **Systèmes internes** : Utiliser les bases de données CRM pour obtenir des informations sur les clients existants.
  - Les données CRM sont riches en informations historiques sur les interactions clients, ce qui aide à mieux comprendre le comportement et les préférences.
  - **Réseaux sociaux** : Utiliser des outils d'analyse pour surveiller les discussions en ligne.
  - Les discussions sur les réseaux sociaux révèlent des opinions spontanées des clients, ce qui permet de mieux comprendre leur perception du produit.
  - **Fournisseurs tiers** : Acheter des données démographiques auprès d'agrégateurs de donnée
  - Cela permet d'enrichir les profils clients avec des données supplémentaires, telles que le revenu moyen dans une région donnée, non disponibles dans les systèmes internes.

- **Méthodes de collecte de données**
  - **Critères de choix :** Le choix des méthodes dépend du type, de la période et du volume des données.
    - **Exemple :** Pour des données en temps réel, privilégier des flux de données automatiques (ex. : API).
    - Les API fournissent des données instantanées, ce qui est essentiel pour les analyses nécessitant une réactivité rapide, comme la surveillance de tendances.

- **Qualité, sécurité et confidentialité des données**

- **Qualité des données**
  - **Critères de qualité :** Les données doivent être exemptes d'erreurs, exactes, complètes, pertinentes et accessibles.
    - **Exemple** : Vérifier l'exactitude des adresses postales pour éviter des erreurs d'envoi.
      - Une erreur dans une adresse postale peut entraîner la perte d'un client si la livraison échoue, ce qui coûte à la fois en termes de satisfaction client et de coûts opérationnels.
  - **Mesure de la qualité :** Définir des points de contrôle pour garantir la qualité des données.
    - **Exemple** : Mettre en place des validations automatiques lors de la saisie des données.
      - Les validations automatiques aident à éviter les erreurs humaines, par exemple, s'assurer que les codes postaux respectent le bon format.

- **Qualité, sécurité et confidentialité des données**
- **Gouvernance des données**
  - **Sécurité et conformité :** Assurer la sécurité, la confidentialité, et la conformité réglementaire.
    - **Exemple** : Respecter le Règlement Général sur la Protection des Données (RGPD) pour protéger les informations personnelles des clients.
      - Le RGPD impose des règles strictes sur la collecte et l'utilisation des données personnelles, et sa non-conformité peut entraîner de lourdes amendes et nuire à la réputation de l'entreprise.

- **Techniques avancées de collecte de données**

- **API et Web Scraping**
  - **API :** Accéder aux données via des interfaces de services en ligne.
    - **Exemple :** Utiliser l'API Twitter pour collecter des tweets mentionnant votre produit.
      - Cela permet de collecter des opinions en temps réel sur un produit, aidant à comprendre la perception publique.
  - **Web Scraping :** Extraction de données à partir de sites web en fonction de paramètres définis.
    - **Exemple :** Extraire des avis de consommateurs sur des plateformes d'e-commerce.
      - Le scraping permet de collecter de grandes quantités d'avis clients pour analyser les points positifs et négatifs d'un produit.

❑ Introduction au processus de transformation des données

- **Définition** : Le processus de transformation des données (Data Wrangling) est une étape indispensable en Data Science qui prépare les données brutes pour une analyse ou des tâches de machine learning.
- **Objectif** : Assurer que les données soient prêtes pour une analyse fiable et précise.
- **Étapes principales** :

1. **Découverte** (Exploration)
2. **Transformation**
3. **Validation**
4. **Publication**

❑ Phase de découverte des données (Exploration)

- **Objectif** : Comprendre la structure et la qualité des données avant toute transformation.
- **Exemple :**
  - Analyse d'un jeu de données sur les ventes pour identifier les colonnes pertinentes (dates, produits, montants).
- **Actions clés** :

Exploration des types de données, détection d'anomalies, identification des données manquantes ou incorrectes.

❑ Phase de transformation des données (1/3) – Structuration

- **Structuration des données** : Modification des formats ou du schéma des données pour uniformiser les sources hétérogènes.
- **Exemple :**
  - Fusion de données provenant de bases de données relationnelles et d'API.
  - **Jointure** : Associer les informations de clients avec celles de leurs commandes.
  - **Union** : Ajouter des enregistrements provenant de régions supplémentaires dans un tableau de ventes.

❑ Phase de transformation des données (2/3) – Normalisation et Dénormalisation

- **Normalisation :** Réduction de la redondance en structurant les données dans plusieurs tables.
- **Exemple :** Séparer les informations des clients et des commandes pour minimiser la duplication.
- **Dénormalisation :** Combiner les tables pour une analyse plus rapide.
- **Exemple** : Fusionner toutes les informations clients dans une seule table pour simplifier les requêtes.

❑ Phase de transformation des données (3/3) – Nettoyage et Enrichissement

- **Nettoyage des données :** Correction des erreurs, gestion des valeurs manquantes et suppression des doublons.
- **Exemple** :
  - Remplacer les valeurs manquantes dans une colonne "âge" par la moyenne.
  - Supprimer les doublons dans une base de données clients.
- **Enrichissement :** Ajouter des informations supplémentaires pour améliorer l'analyse.
- **Exemple** : Ajouter des données météorologiques pour mieux comprendre l'impact des conditions climatiques sur les ventes.

❑ Phase de validation des données

- **Objectif** : Vérifier que les données transformées sont de qualité et prêtes pour l'analyse.
- **Exemple** :
  - Validation des âges (ex : aucune valeur inférieure à 18 ans dans une étude démographique).

❑ Phase de publication des données

- **Objectif** : Préparer et publier le jeu de données final, prêt pour l'analyse ou le machine learning.
- **Exemple** :
  - Publier un dataset de ventes mensuelles nettoyé et agrégé pour l'équipe de marketing.

❑ Outils et logiciels pour la transformation des données

- **Outils couramment utilisés** :
  - Feuilles de calcul (Excel, Google Sheets avec Power Query).
  - OpenRefine, Google DataPrep, Trifacta Wrangler.
  - Python (pandas, numpy), R (dplyr).
- **Exemple** : Utilisation d'Excel Power Query pour nettoyer un fichier CSV et le préparer pour une analyse de ventes.

❑ Étapes du nettoyage des données

- Phases du nettoyage :

1. Inspection : Identifier les problèmes de qualité (valeurs manquantes, doublons).
2. Nettoyage : Corriger les anomalies détectées.
3. Vérification : Assurer que les corrections sont conformes aux règles établies.

Inspection et profilage des données

- **Profilage des données** : Analyse des structures et détection des anomalies (types incorrects, valeurs aberrantes).
- **Exemple** : Profilage des données de ventes pour détecter des valeurs incohérentes dans les montants des commandes.

Techniques de nettoyage des données

- **Gestion des valeurs manquantes** :
  - Filtrer les enregistrements incomplets ou utiliser l'imputation pour calculer des valeurs manquantes.
- **Suppression des doublons** : Éviter les enregistrements répétitifs.
- **Conversion de type** : S'assurer que les données numériques sont correctement formatées (ex : prix sous forme de nombre).

Vérification post-nettoyage

- **Objectif** : S'assurer que les données nettoyées sont valides et conformes aux attentes.
- **Exemple** : Re-vérification des valeurs de dates pour garantir leur cohérence après nettoyage.

Exemples d’utilisation de la transformation des données

- **Secteur financier** : Préparer des données financières pour des rapports précis.
- **Vente au détail** : Nettoyer et enrichir les données de ventes pour une meilleure analyse des tendances.

❑ Introduction à la statistique et à son rôle dans l'analyse de données

- **Définition de la statistique** :
  - Branche des mathématiques dédiée à la **collecte, l'analyse, l'interprétation** et la **présentation des données**.
  - Utilisée dans divers domaines pour des décisions basées sur les données (ex. : analyse de l'efficacité des vaccins, compréhension des comportements clients).
- **Lien avec l'analyse de données** :
  - Permet d'extraire des insights pertinents pour comprendre les données et guider la prise de décision.

❑ Analyse statistique : Statistiques descriptives et inférentielles

- **Statistiques descriptives** :
  - Résumer les données par des graphiques, tableaux et mesures de tendance centrale (moyenne, médiane, mode).
  - Exemple : Calculer la moyenne des scores d'une classe de 25 étudiants.
- **Statistiques inférentielles** :
  - Tirer des conclusions sur une population à partir d'un échantillon.
  - **Méthodes courantes** : tests d'hypothèse, intervalles de confiance, régression.
  - **Exemple** : Utiliser un test d'hypothèse pour évaluer l'efficacité d'un nouveau traitement médical.

❑ Exploration de données : Définition et objectifs

- **Qu'est-ce que l'exploration de données ? :**
  - Processus d'extraction de connaissances à partir des données pour identifier des **modèles**, **corrélations** et **tendances**.
  - Utilise des méthodes issues de la **reconnaissance de motifs**, de l'**analyse statistique** et des **techniques mathématiques**.
- **Objectifs :**
  - **Comprendre les tendances :** Ex. : Évolution des températures globales à long terme.
  - **Prédire des probabilités :** Ex. : Prédire la probabilité de défaillance d'une machine.

❑ Techniques courantes de l'exploration de données

- **Classification** :
  - Assigner des catégories aux données (ex. : classer les clients par niveau de dépense).
- **Clustering** :
  - Regrouper les données similaires (ex. : segmenter des clients selon leurs comportements d'achat).
- **Détection des anomalies** :
  - Identifier les valeurs anormales dans les données (ex. : détection d'utilisations inhabituelles d'une carte de crédit).
- **Exploration de règles d'association** :
  - Découvrir des relations entre les événements (ex. : achat d'un ordinateur souvent accompagné de l'achat d'un coussin de refroidissement).

❑ Outils pour l'exploration de données : Aperçu des solutions disponibles

- **Feuilles de calcul :**
  - **Microsoft Excel et Google Sheets pour des analyses de base.**
  - **Tableaux croisés dynamiques pour visualiser des aspects spécifiques.**
  - **Compléments pour Excel :** Data Mining Client, XlMiner.
- **R :**
  - Langage statistique avec des bibliothèques pour la modélisation, l'exploration de texte et la détection des valeurs aberrantes.
- **Python :**
  - **Bibliothèques courantes** : Pandas, NumPy pour l'analyse de données.

❑ Critères de sélection des outils d'exploration de données

- **Facteurs à considérer :**
  - **Taille et structure des données**.
  - **Capacités de visualisation** : Intégration avec des outils de création de graphiques.
  - **Facilité d'utilisation** : Pour les utilisateurs techniques et non techniques.
  - **Exemple** : Choisir entre Excel pour une analyse rapide et Python pour une analyse plus avancée.

❑ Exemples d'application de l'exploration de données

- **Secteur financier** : Suivi des transactions pour la détection de la fraude.
- **Santé** : Prédiction des risques pour établir les priorités de traitement.
- **Éducation** : Analyse des performances des élèves pour cibler le soutien nécessaire.
- **Logistique** : Alignement de l'offre sur la demande à l'aide de prévisions.

❑ Raconter une histoire avec les données

- **Pourquoi la narration est-elle essentielle ?**
  - Les humains comprennent mieux les concepts à travers des **histoires**. Une narration claire aide à relier les données à des **contextes réels**.
  - **Équilibre entre simplicité et complexité** : Il est crucial de trouver un équilibre entre une présentation claire et la transmission de la complexité des données.
  - **Exemple** : Pour convaincre la direction d'investir dans une nouvelle campagne, il est plus percutant de raconter l'histoire de la montée en flèche des ventes après une précédente campagne, plutôt que de simplement présenter des chiffres.
- **Étude de Stanford :**
  - Les histoires sont plus mémorables que les simples faits et chiffres. Les présentations intégrant des récits laissent une empreinte durable.

❑ Adapter la communication à l'audience

- **Comprendre son public :**
  - **Questions clés** : Qui est mon public ? Quels sont leurs intérêts et besoins ? Quel niveau de détail est nécessaire ?
  - **Importance de la confiance :** Les sources de données et les hypothèses doivent être transparentes pour établir la crédibilité.
- **Structure de la présentation :**
  - **Approche descendante** (des résultats aux détails) ou **ascendante** (des détails aux conclusions).
  - **Exemple** : Présentation pour la direction avec un focus sur les résultats principaux, tandis qu'une session technique avec les analystes inclura davantage de détails sur la méthodologie.

❑ Visualisation des données : Concepts clés et objectifs

- **Qu'est-ce que la visualisation des données ?**
  - Représentation graphique des données pour **faciliter la compréhension et l'interprétation**.
  - Permet de détecter des **tendances, corrélations et anomalies** qui seraient difficiles à identifier dans des tableaux bruts.
- **Pourquoi visualiser ?**
  - **Exemple** : Comparer la croissance des ventes annuelles sur un graphique linéaire est plus intuitif que de lire une liste de chiffres.

Objectif : Simplifier des ensembles de données complexes pour une meilleure prise de décision.

❑ Choisir le bon type de visualisation

- **Types de graphiques courants** :
  - **Graphiques à barres** : Comparaison entre catégories (ex. : ventes par produit).
  - **Graphiques en colonnes** : Idéal pour montrer les changements au fil du temps (ex. : évolution mensuelle des ventes).
  - **Graphiques à secteurs (camembert)** : Affichage de la proportion des sous-parties (ex. : part de marché des différents produits).
  - **Graphiques linéaires** : Suivi des tendances continues (ex. : progression des ventes sur plusieurs années).
- **Questions à se poser** :
  - Quel type de relation souhaitez-vous montrer ? (comparaison, évolution, corrélation)
  - **Exemple** : Utiliser un graphique en colonnes pour comparer les ventes d'un produit sur trois ans.