Modélisation statistique et analyse de données — Filière :(2IDL)

Série 2 — Années: 2026/2027

Prof : O. Zealouk

Exercice 1 :

Utiliser la bibliothèque BeautifulSoup pour effectuer les tâches suivantes à partir du code HTML fourni :

```
<html><body><h1>IA</h1><h2>Python</h2></body></html>
```

1. Créer un objet BeautifulSoup à partir du code HTML fourni.
2. Afficher le code HTML avec une indentation correcte afin de le rendre plus lisible.
3. Afficher les éléments directement contenus dans la balise <body>.

Exercice 2 :

Utilise la bibliothèque BeautifulSoup pour accomplir les tâches suivantes à partir du fichier HTML web_scraping.html :

1. Extraire et afficher le titre de la page
2. Extraire le titre (contenus dans les balises <h1>).
3. Extraire les titres des articles (contenus dans les balises <h2>).
4. Compter le nombre total d'articles présents dans la page HTML et afficher ce nombre
5. Extraire les descriptions des articles (contenues dans les balises <p> avec la classe description).
6. Extraire les liens des articles (contenus dans les attributs href des balises <a> avec la classe link).
7. Regrouper les informations extraites de chaque article de manière à ce que chaque titre soit associé à sa description et à son lien.
8. Rechercher un mot-clé (par exemple : "2024") dans les titres et afficher les articles correspondants.
9. Exporter toutes les données regroupées dans un fichier CSV nommé articles.csv.

Exercice 3 :

1. Charger la page HTML à partir d'un fichier nommé scraping2.html.
2. Extraire les informations suivantes :
   - Les titres des articles (contenus dans <h3>)
   - Les auteurs et dates (dans les balises <p class="author">).
   - Les descriptions des articles.

- Les mots-clés associés à chaque article (contenus dans <ul class="tags">).
- Les liens des articles.

3. Créer un dictionnaire organisé par catégorie :
   - Chaque catégorie (id des sections) doit contenir une liste d'articles avec leurs informations.
4. Filtrer les articles selon un mot-clé (dans les tags) :
   - Par exemple, extraire uniquement les articles liés à "Technologie".