Chapitre 2

GENERALITES SUR LES LANGAGES

1. Introduction

Les langages peuvent prendre des formes très diverses selon la nature de ce qu'ils expriment : langage naturel, langage mathématique, langage de programmation (Pascal, C...), langages formels...

Une première formalisation de La description des langages formels a été proposée par le linguiste **Noam CHOMSKY (1950)**. Un langage formel est constitué d'un vocabulaire et de règles de grammaires entièrement connus. La théorie des langages formels s'occupe soit de générer l'ensemble des phrases (mots) d'un langage soit de déterminer si une phrase appartient ou non au langage.

Remarque

L'analyse ou la génération de phrases est, dans ce contexte, purement syntaxique. Elle est indépendante de la signification des symboles utilisés et des mots produits et/ou reconnus.

2. Mots

Définition

Un **symbole** est une brique élémentaire, un atome.

Si $a \in A$ atome alors $\forall\ x, y \in A, a \neq x + y$.

Un **alphabet** A est un ensemble fini et non vide de symboles.

Un **mot m** (ou **chaîne**) sur un alphabet A est une suite finie $m_1 m_2 \cdots m_n$ de lettres de A. L'entier n est appelé la longueur du mot m, notée |m|.

Le **mot vide** est le mot de longueur 0, c'est-à-dire ne contenant aucun symbole. Il est souvent noté ε.

Remarque

Les **alphabets** seront décrits comme des ensembles de **symboles** (entre accolades), composés de plusieurs caractères. Les symboles représentés par des signes de ponctuation seront entre quottes.

Remarque

Soit l'alphabet {a, b, c, h, ch, ';', ','}.

ch et c + h ≡ ch sont théoriquement différents : ch (|ch| = 1) et c + h ≡ ch (|c + h| = 2).

Notation

• a, b, c, d, e, f, 0, 1... désignent des symboles.

• t, u, v, x, y, z désignent des chaînes.

• La chaîne aaaa est aussi notée a^4 (a^0=ε).

• Le symbole m(i) désigne le i-ème symbole de la chaîne m.

Remarque

L'opération particulière définie sur les mots est la **concaténation**. Soient x et y deux chaînes, la concaténation de x et y est xy.

N.B. La concaténation n'est pas commutative.

La chaîne vide ε est un élément neutre pour la concaténation x ε = ε x = x.

Définition

Étant donné un alphabet A :

- A* : ensemble de tous les mots sur A.
- Dans A*, une opération **concaténation** est définit.

u et v deux mots de longueur p et q, la concaténation de u et v (dans cet ordre) est le mot w de longueur p+q défini par : w(i) = u(i) pour $1 \leq i \leq p$ et w(p+i) = v(i) pour $1 \leq i \leq q$.

Remarque

- L'ensemble A* des mots ainsi construit est infini dénombrable.
- Les symboles de l'alphabet sont atomiques, ie : si $a \in A$, $\forall x,y \in A^+$, $a \neq xy$
- Il n'y a pas d'inverse pour l'opération de concaténation, ie : si $u \in A^+$, $\forall v \in A^+$, $uv \neq \varepsilon$

3. Théorème de la Décomposition

Tout mot x (de longueur n = |x|) sur un alphabet A se décompose de façon unique en $x_1 + x_2 + ... + x_n$, également noté $x_1x_2...x_n$, où $\forall i \in [1..n]$, $x_i \in A$.

Démonstration

Comme les symboles de l'alphabet sont des atomes, il n'est pas possible de diviser un mot plus qu'au niveau de ces symboles. Si deux divisions en symboles étaient possibles, cela voudrait dire qu'un symbole peut être divisé et donc il ne serait pas atomique.

Remarque

Une chaîne sur un alphabet A peut également être définie récursivement par :

- la chaîne vide ε est une chaîne sur A;
- si x est une chaîne sur A et a ∈ A alors la chaîne ax et xa sont des chaînes (mots) sur A (Attention, dans le cas général, ax ≠ xa);
- aucun autre objet n'est une chaîne sur A.

Notation

A^n : ensemble des mots (ou chaînes) de longueur n (pour n ∈ N) construits sur A

$(A^n = \{x_1x_2...x_n \mid \forall\ i,\ 1 \le i \le n,\ x_i \in A\})$

Par conséquent : toutes les chaînes *y* de l'ensemble A^3 ont pour longueur |y|=*3*.

A^+ : L'ensemble des chaînes de longueur finie et non nulle définies sur A.

$A^+ = \cup_{n=1..\infty} A^n = \{x / n \in N, n \ge 1 \text{ et } x \in A^n\}$

$A^* = A^+ \cup \{\varepsilon\}$

Par convention :

$A^0 = \varepsilon$

$A^* = \cup_{n=0..\infty} A^n$

4. Relations entre mots

Définition

Si x et y sont deux chaînes quelconques sur A, alors :

x est un **préfixe** de y (x ∈ Pref(y)) s'il existe z dans A* tel que y = xz, autrement dit x ∈ Pref(y) si et seulement si ∃ z ∈ A*, y = xz ;

x est un **suffixe** de y (x ∈ Suff(y)) s'il existe z dans A* / y = zx, autrement dit x ∈ Suff(y) si et seulement si ∃ z ∈ A*, y = zx ;

x est une **sous-chaîne** (ou **facteur**) de y s'il existe w et z dans A* tel que y = wxz, autrement dit x ∈ Fact(y) si et seulement si ∃ w, z ∈ A*, y = wxz ;

Si $x \neq y$ (c'est-à-dire si $z \neq \varepsilon$), alors le préfixe ou le suffixe est dit **propre**.

$Pref(x) \subset Fact(x)$ et $Suff(x) \subset Fact(x)$.

Définition

Une **occurrence** d'une chaîne x dans une chaîne y est une apparition de x à un endroit précis dans la chaîne y.

5. Relations d'ordre

Soit A* défini sur $A = \{x_1, x_2, ..., x_n\}$, il est possible de définir plusieurs relations d'ordre.

5. 1. Ordre préfixiel

Ordre partiel définit par : $u < v$ si et seulement si u est un préfixe propre de v.

5. 2. Ordre lexicographique

- Ordre total défini par : $u < v$ si et seulement si $u = wau_2$ et $v = wbv_2$ tels que $w \in A^*$, $a < b$ avec a et $b \in A$;

- $u<v$ si et seulement si $u = aw$, $v = bz$ et $(a < b)$ ou $((a = b)$ et $(w < z))$, $a, b \in A$ et $w, z \in A^*$ avec $\varepsilon < t \ \forall t \in A^+$. Tout ceci est valable si et seulement si $\forall x_i, x_j \in A$, $x_i \leq x_j$ si $i \leq j$.

5. 3. Ordre hiérarchique

Ordre total pour lequel les mots sont classés en premier lieu par longueur, puis pour les mots de même longueur, par ordre lexicographique.

6. Langages et opérations

Définition

Un langage L sur un alphabet A est un ensemble de chaînes (ensemble de mots) sur A. L est un sous-ensemble de A*, autrement dit $L \subset A^*$. L'ensemble des langages L sur A est l'ensemble $P(A^*)$ des parties de A^*, autrement dit : $L \subset P(A^*)$.

Définition

Étant donné un alphabet A, parmi tous les langages L de P(A*) :

Langage neutre : langage dont le seul mot est la chaîne vide, $L = \{\varepsilon\}$.

Langage vide : langage qui ne contient aucun mot, soit $L = \emptyset$. $\emptyset \neq \{\varepsilon\}$

Un ***langage L*** est dit posséder la propriété ***préfixe*** (resp. ***suffixe***) si aucune chaîne de L n'est préfixe propre (resp. suffixe propre) d'une autre chaîne de L.

Remarque

Comme les langages sont des ensembles, des opérations ensemblistes classiques peuvent être appliquées : union, intersection, complémentation, ... De plus, par extension de la concaténation des mots aux langages, quelques nouveaux opérateurs peuvent être définis.

Définition

Soit A un alphabet. Sur les langages de P(A*) les opérateurs suivants sont définis: soient L et M deux langages sur A,

6. 1. Opérateurs ensemblistes classiques

Union : $L \cup M = \{x \mid x \in L \text{ ou } x \in M\}$;

Intersection : $L \cap M = \{x \mid x \in L \text{ et } x \in M\}$;

Différence (ou exclusion) : $L\backslash M = L-M = \{x \mid x \in L \text{ et } x \notin M\}$;

Complémentaire sur A* : $Comp(L)= A^*\backslash L = \{x \mid x \in A^* \text{ et } x \notin L\}$;

6. 2. Opérateurs induits par la concaténation des mots

Produit des langages : $LM = L\times M = \{xy \mid x \in L \text{ et } y \in M\}$;

Fermeture de Kleene : $L^* = \cup_{i=0..\infty} L^i$ où $L^0 = \{\varepsilon\}$ et $L^n = LL^{n-1} = L^{n-1}L$;

Fermeture positive : $L^+= \cup_{i=1..\infty} L^i$.

Remarque

Le produit est parfois appelé "concaténation de deux langages". Cette concaténation est notée × (et le symbole × est souvent omis), mais il s'agit bien de deux concaténations différentes : l'une entre mots et l'autre entre ensembles de mots.

La concaténation de deux langages est l'ensemble des mots obtenus en concaténant un mot du premier langage avec un mot du second.

Propriété

- Le langage vide est absorbant pour la concaténation des langages : $\emptyset L = \emptyset = L\emptyset$
- $L^+ = LL^* = L^*L$
- $L^* = \{\varepsilon\} \cup L^+$
- $\emptyset^* = \{\varepsilon\}$
- $\{\varepsilon\}^* = \{\varepsilon\}$