Chapitre 3

LES LANGAGES RATIONNELS

1. Introduction

Parmi tous les langages constitués par les parties de A^* **engendrés** par un alphabet A, une classe particulière est distinguée : la classe *Rat(A*)* des *langages rationnels* sur A. L'intérêt de cette classe est qu'il existe une méthode simple permettant de décider pour chacun de ses langages si un mot lui appartient ou non : **Automates Finis**.

2. Langages rationnels

Définition

Soit A un alphabet. Les **langages rationnels sur A** (appelés aussi **langages réguliers**) sont les éléments de la classe Rat(A*) définie inductivement de la façon suivante : Rat(A*) est le plus petit sous-ensemble de P(A*) tel que :

1. $\emptyset \in Rat(A^*)$;
2. $\{\varepsilon\} \in Rat(A^*)$;
3. $\forall\ a \in A, \{a\} \in Rat(A^*)$;
4. Si $L_1 \in Rat(A^*)$ et $L_2 \in Rat(A^*)$ alors $L_1 \cup L_2 \in Rat(A^*)$;
5. Si $L_1 \in Rat(A^*)$ et $L_2 \in Rat(A^*)$ alors $L_1 \times L_2 \in Rat(A^*)$;
6. Si $L_1 \in Rat(A^*)$ alors $L_1^* \in Rat(A^*)$.

3. Théorème des parties finies

Toute partie finie L de A* est dans Rat(A*).

Démonstration

Comme toute partie finie peut être vue comme la réunion de singletons, L peut être obtenu par un certain nombre d'applications des points 1 à 5 et en utilisant le théorème de décomposition unique d'un mot.

Remarque

A l'aide des opérateurs de la définition précédente, de nombreux langages désignés par des expressions mathématiques peuvent être construits.

Remarque

Il existe pour les langages rationnels une écriture simplifiée, plus compacte et pratique appelée les expressions rationnelles. Chaque expression rationnelle décrit un langage rationnel précis.

4. Expressions rationnelles

Définition

Les **expressions rationnelles** sur A décrivent les **langages rationnels**. Elles sont définies de la façon suivante :

1. ∅ est une expression rationnelle qui décrit le langage rationnel ∅ ;

2. ε est une expression rationnelle qui décrit le langage rationnel {ε} ;

3. pour tout a de A, a est une expression rationnelle qui décrit le langage rationnel {a} ;

4. Si l_1 et l_2 sont des expressions rationnelles qui décrivent L_1 et $L_2 \in Rat(A^*)$ alors :

a. $(l_1 \mid l_2)$ et $(l_1 + l_2)$ sont des expressions rationnelles identiques qui décrivent le langage rationnel $L_1 \cup L_2 \in Rat(A^*)$,

b. $(l_1 l_2)$ et $(l_1.l_2)$ sont des expressions rationnelles identiques qui décrivent le langage rationnel $L_1 \times L_2 \in Rat(A^*)$,

c. $(l_1)^*$ est une expression rationnelle qui décrit le langage rationnel $(L_1)^*$.

Comme la réunion et la concaténation sont associatives, les parenthèses inutiles sont effacées. *(u | v | w)* remplacera *((u |v) | w) ou (u | (v | w))*.

N.B.

Il est sous-entendu qu'aucun des symboles "|", "*", "ε", "(" et ")" n'appartient à l'alphabet *A*. Sinon, il faut soit les différencier en renommant les symboles, soit les entourer de guillemets.

Théorème

Tout langage dénoté par une expression rationnelle est un langage rationnel.

Soit A un alphabet et C = { |, *, ε, (,)} tel que A ∩ C = ∅ ;

Un élément w est une expression rationnelle si et seulement si :

- $w \in A^*$;
- w est de la forme w_1^*, $w_1 w_2$ ou $w_1 \mid w_2$ avec w_1 et w_2 des expressions rationnelles.

Une expression rationnelle désigne un langage rationnel de la façon suivante :

- $w \in A^*$ désigne le langage dont le seul mot est w (w peut être ε) ;
- soient w_1 et w_2 des expressions rationnelles désignant les langages $L(w_1)$ et $L(w_2)$ alors:

- w_1w_2 désigne le langage dont chaque mot est obtenu en concaténant (juxtaposant) un mot du langage désigné par w_1 avec un mot du langage désigné par w_2 (dans l'ordre) : $L(w_1)\ L(w_2)$;
- w^* désigne le langage dont chaque mot est obtenu en concaténant un nombre quelconque (éventuellement nul) de mots du langage désigné par w : $(L(w))^*$;
- $w_1|w_2$ (parfois notée w_1+w_2) désigne la réunion des langages désignés par w_1 et w_2. Les mots de $w_1|w_2$ sont ceux qui appartiennent à w_1 ou à w_2 : $L(w_1) \cup L(w_2)$.

Notation

- $w^+ = w\ w^* = w^*\ w$;
- w? est une abréviation pour $w \mid \varepsilon$;
- la notation [a, b, c], où a, b et c sont des symboles, abrège l'expression rationnelle a|b|c. Une classe de caractères comme [a-z] abrège l'expression rationnelle a | b | ... | z.
- w^n, pour un $n \geq 0$ désigne la chaîne composée de n occurrences du mot du langage désigné par w. Si n est quelconque : $w^n\ (n \geq 0) \equiv w^*$; $w^n\ (n > 0) \equiv w^+$.

Notation

w^n : un langage rationnel quand n est un entier fixé, par contre, ce n'est pas toujours vrai dans le cas général, quand n est une variable.

En effet, le langage désigné par a^nb^n n'est pas rationnel : il s'agit des mots commençant par un certain nombre de a et suivis **du même nombre** de b. Ce langage ne peut pas être obtenu à partir des parties finies d'un alphabet A par simple application des opérations ×, U et *. Ceci illustre bien le fait que tout langage sur A n'est pas nécessairement rationnel.

Définition

Une expression rationnelle est dite **standard** si et seulement si les seuls opérateurs utilisés sont les opérateurs ×, ∪ et *.

Remarque

Il se peut que deux expressions différentes puissent décrire un même langage. a*a et aa* désignent toutes deux l'ensemble des chaînes de n a consécutifs pour n>0.

Définition

Deux expressions rationnelles w_1 et w_2 sont dites équivalentes (ou par abus de langage "égales"), noté "$w_1 \equiv w_2$" (ou "$w_1 = w_2$"), si elles décrivent le même langage rationnel.

Propriété

Soient u, v et w des expressions rationnelles :

Union

u|v = v|u (commutativité)

u|u = u (idempotence)

u|∅ = u (∅ : élément neutre)

u|(v|w) = (u|v)|w (associativité)

La mise à l'étoile

$u^{**} = u^*$ (idempotence)

∅* = ε

La mise à l'étoile et l'union

u* = u|u* (absorption)

La concaténation

• uε = εu = u (ε : élément neutre à gauche et à droite)

• u∅ = ∅u = ∅ (∅ : élément absorbant à gauche et à droite)

• u(vw) = (uv)w (associativité)

La concaténation et l'union

• (u|v)w = uw|vw (distributivité à droite de la concaténation par rapport à l'union)

• u(v|w) = uv|uw (distributivité à gauche de la concaténation par rapport à l'union)

Remarque

uw ≠ wu (la concaténation n'est pas commutative) ! sauf si u = w.

Définition

Un **facteur itérant** est une sous-chaîne non vide pouvant être "étoilée". Autrement dit, v est facteur itérant de m ∈ L si m = uvw, |v| ≠ 0, ∀ i, $uv^iw \in L$ ($uv^*w \subset L$).

Définition

Un **mot primitif** est un mot u tel que $u = v^n$ si n=1, c'est-à-dire s'il n'est pas puissance d'un autre mot que lui-même.

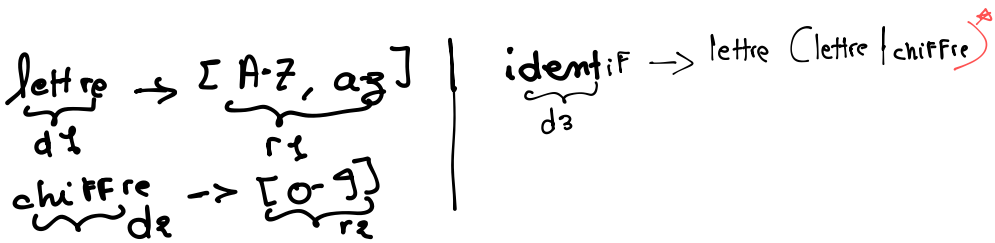
5. Définitions rationnelles

Si A est un alphabet de symboles de base, une **définition rationnelle** est une suite de n définitions (n ∈ N) de la forme $\mathbf{d_i} \rightarrow r_i$ (pour i ∈ {1,..., n}), où chaque $\mathbf{d_i}$ est un nom distinct, n'appartenant pas à (A ∪ {|, *, ε, (,)})*, et chaque r_i une expression rationnelle sur l'alphabet augmenté A ∪ {d_1, ..., d_{i-1}}.

d_i engendre r_i or r_i dérive de d_i

Exemple : les identificateurs

[A-Z, a-z][A-Z, a-z, 0-9]*



Remarque

- Chaque membre droit (r_i) d'une règle ($\mathbf{d_i} \rightarrow r_i$) ne peut faire intervenir que les nouveaux symboles définis **antérieurement** (les $\mathbf{d_j}$ tels que $j<i$) ;
- Généralement, il n'y a pas de définition récursive, comme le serait par exemple la définition caractérisée par l'unique règle $\mathbf{X} \rightarrow a\mathbf{X}b|ab$, qui engendre pour **X** le langage $\{a^nb^n \mid n \in N\}$. En effet, si l'on autorisait l'écriture de définitions récursives, on pourrait caractériser des langages qui ne sont pas rationnels, comme par exemple $\{a^nb^n \mid n \in N\}$.

Une seule définition récursive, est autorisée : la récursivité droite, c'est-à-dire des définitions de la forme $\mathbf{X} \rightarrow x\mathbf{X}|y$ avec x et y des expressions rationnelles.

6. Systèmes d'équations rationnelles

Les définitions rationnelles permettent de proposer des expressions rationnelles plus lisibles. Cependant, il est parfois nécessaire d'obtenir une expression rationnelle ne comportant que des symboles du vocabulaire. Il faut donc alors essayer de trouver cette expression. La simple substitution n'est pas toujours suffisante, surtout en cas de récursivité. La solution consiste à passer par la résolution d'un système d'équations rationnelles. La transformation s'effectue en utilisant directement les définitions rationnelles. L'opérateur → devient =, l'opérateur | devient +, parfois ε devient 1 et les identificateurs deviennent des variables. La résolution du système ainsi obtenu donne l'expression rationnelle du langage.

Définition

Les **systèmes d'équations rationnelles** sont des ensembles d'équations dont les coefficients sont des expressions rationnelles.

Remarque : Les solutions ne sont pas uniques.

Définition

Un ensemble d'équations rationnelles d'indéterminés $D = \{X_1, ..., X_n\}$ est en forme standard si $\forall X_i \in D$, il y a une équation de la forme : $X_i = a_{i0} + a_{i1}X_1 + ... + a_{in}X_n$ avec a_{ij} des expressions rationnelles sur A telles que $A \cap D = \emptyset$.

Remarque

Il est possible d'avoir $a_{ij} = \emptyset$ quand il n'y a pas de terme correspondant à X_j dans l'équation de X_i. $\emptyset$ joue le rôle de 0 ; ε celui de 1 (l'équation pour X_i comporte alors X_j sans coefficient à droite).

6. 1. Lemme d'Arden

Soient K et L deux langages sur A* ($K \subseteq A^*$ et $L \subseteq A^*$), $\varepsilon \notin K$, alors :

1) K*L est l'unique solution de l'équation $X = KX + L$.

2) LK* est l'unique solution de l'équation X = XK + L.

Si $\varepsilon \in K$, alors A* est solution et K*L la plus petite solution.

De ce lemme, il est possible de démontrer un certain nombre d'**identités rationnelles** très utiles pour démontrer des équivalences d'expressions rationnelles ou pour simplifier des expressions.

En particulier, les identités suivantes :

$(a + b)^* = a^* (ba^*)^*$ (e_1)

$(a + b)^* = (a^*b)^* a^*$ (e_2)

$(ab)^* = 1 + a (ba)^* b$ (e_3)

6. 2. Algorithme de résolution

Soit un système de n équations rationnelles notées $X_1, ..., X_n$. Cette méthode se déroule en trois phases :

a) Écrire, quand c'est possible, les équations du système sous la forme : $X_i = x_iX_i + Y_i$ avec x_i expression rationnelle sur A et Y_i expression rationnelle de la forme $y_0 + y_1X_1 + ... + y_{i-1}X_{i-1} + y_{i+1}X_{i+1} + ... + y_nX_n$ où y_i des expressions rationnelles sur A.

b) Pour toutes les équations X_i de X_1 à X_{n-1}, sachant que selon le lemme d'Arden, l'unique solution pour $X_i = x_iX_i+Y_i$ est $x_i^*Y_i$, remplacer dans toutes les équations $X_{i+1}... X_n$ la variable X_i par $x_i^*Y_i$.

c) Pour toutes les équations X_i de X_n à X_1, calculer la valeur de X_i en appliquant le Lemme d'Arden et remplacer X_i par cette valeur dans toutes les équations de X_{i-1} à X_1.

Remarque

Il faut penser à simplifier continuellement les expressions rationnelles pour avoir un résultat le plus simple possible. De plus, en fonction des simplifications choisies et de l'ordre adopté, les résultats ne sont pas toujours identiques (du point de vue des expressions obtenues) mais toujours équivalents.

7. Lemme de l'étoile (de la pompe)

Soit L un langage rationnel sur un alphabet A. Alors il existe un entier naturel n tel que pour tout mot z de L vérifiant $|z| > n$, il existe u, v, w $\in$ A* tels que z = uvw, $v \neq \varepsilon$, $|uv| \leq n$ et pour tout i $\in$ N, $uv^iw \in L$.

Attention

Ce lemme peut s'appliquer à des langages qui ne sont pas rationnels. Mais tout langage rationnel vérifie ce lemme. $Rat(A^*) \subset Etoile(A^*) \subset P(A^*)$

Remarque

1) Ce théorème permet souvent de **démontrer *par l'absurde* qu'un langage L n'est pas rationnel** : il suffit de montrer que, **pour tout n de N**, **il existe un mot** z de L qui ne vérifie pas la condition **pour un i donné**.
2) Par contre, **montrer qu'un langage vérifie le lemme de l'étoile ne prouve pas qu'il est rationnel**.

Exemple

Le langage $\{a^m b^m \mid m \in N\}$ est il rationnel?

Hypothèses : Il existe un entier positif $n \in N$, tel que $\forall\ z \in L$, $|z| > n$, (H1) $\exists$ u,v,w, tels que $z = uvw$, (H2) $v \neq \varepsilon$, (H3) $|uv| \leq n$, (H4) $\forall\ i \in N$, $uv^i w \in \{ a^m b^m \mid m \in N\}$

Considérons le mot $z = a^n b^n$ ($|z| = 2n$, donc $|z| > n$). Soient u, v et w tels $z = uvw$ (H1) et vérifiant H2, H3 et H4 (z est plus long que n et par hypothèse, u, v et w existent).

Tout préfixe de z de longueur $l \leq n$ est nécessairement composé uniquement de a. Comme uv est un préfixe de z (H1 : $z = uvw$) et $|uv| \leq n$ (H3), ceci est vrai en particulier de uv. Donc il existe k, $p \in N$ ($p \neq 0$) tels que $u = a^k$, $v = a^p$ (H2 : $v \neq \varepsilon$) et $k+p \leq n$.

On a $z = uvw = a^k a^p w$, avec $w = a^{n-(k+p)} b^n$ (car $z = a^n b^n$).

H4 s'écrit alors $\forall\ i \in N$, $a^k (a^p)^i a^{n-(k+p)} b^n \in \{a^m b^m \mid m \in N\}$,

or ceci est faux : $a^k (a^p)^i a^{n-(k+p)} b^n = a^k a^p (a^p)^{i-1} a^{n-(k+p)} b^n$

$$= a^k a^p a^{n-(k+p)} (a^p)^{i-1} b^n = a^n (a^p)^{i-1} b^n$$

comme $p \neq 0$, pour n'importe quel $i > 1$, $a^n (a^p)^{i-1} b^n \notin L$.

Donc l'hypothèse est fausse et d'après le théorème de l'étoile $\{a^m b^m \mid m \in N\}$ n'est pas un langage rationnel.