# Chapitre 4

# LES GRAMMAIRES DE CHOMSKY

## 1. Introduction

Un langage est défini par l'ensemble de ses mots et de ses phrases correctes. Il est impossible de donner la liste des phrases (ou mots) correctes d'un langage parce qu'elle est souvent infinie. Pour les langages rationnels nous pouvons les dénoter par des expressions rationnelles. Toutefois, tous les langages ne sont pas rationnels et cette solution n'est donc pas toujours possible.

Pour atteindre d'autres classes de langage, divers types de grammaires sont utilisés. Les grammaires peuvent être vues comme des "algorithmes" d'une part pour construire les mots du langage et d'autre part pour vérifier la validité d'un mot par rapport à un langage.

## 2. Structures d'une grammaire

Une grammaire à structure de phrase G permet de caractériser un langage L(G), qui est un ensemble de phrases (ou mots), appelé le langage engendré par la grammaire. Une telle grammaire ressemble à une définition rationnelle.

1. $\mathbf{V_T}$ : vocabulaire terminal dont chaque élément est appelé symbole terminal. Ce vocabulaire correspond à l'alphabet pour les langages rationnels et les symboles terminaux aux symboles de l'alphabet. $L(G) \subseteq V_T^*$. Dans ce cours, ne seront considérer que les vocabulaires terminaux composés de symboles (lettres, chiffres, caractères spéciaux comme '+', '-', ';'...). En **compilation**, ce vocabulaire est un ensemble d'unités lexicales (identificateurs réservés ou non, paramètres, nom, opérateurs...).

2. $\mathbf{V_N}$ : vocabulaire non terminal dont chaque élément est appelé symbole non terminal. Les symboles non terminaux peuvent être vus comme les nouveaux symboles des définitions rationnelles (utilisés comme membres gauches des règles). Ils ont toutefois un rôle un peu plus large. Ils n'appartiennent pas au vocabulaire de base (terminaux) et sont destinés à être éliminés, remplacés pour former les mots du langage.

3. Des **règles** permettant de déterminer quelles séquences de $V_T^*$ sont légales. Ces règles ressemblent à celles des définitions rationnelles mais sont plus souples et plus générales.

**Définition**

Une **grammaire formelle**, appelée aussi **grammaire de Chomsky**, G est une description de la forme des symboles et des phrases d'un langage noté L(G). Elle est définie par un quadruplet $G = (V_T, V_N, S, R)$ où :

**a)** $V_T$ est un ensemble fini non vide : le vocabulaire terminal ou alphabet; $L(G) \subseteq V_T^*$ .

**b)** $V_N$ est un ensemble fini non vide : le vocabulaire non terminal (on parle aussi de variable ou de catégorie syntaxique) ;

$V_T \cap V_N = \emptyset$ ; $V = V_T \cup V_N$ : le vocabulaire de la grammaire;

**c)** $S \in V_N$ est un symbole non terminal particulier appelé l'axiome (symbole de départ);

**d)** R est un ensemble de **règles**, appelées **règles de production** (ou **règles de réécriture**), de la forme $\alpha \rightarrow \beta$ avec $\alpha \in V^+$ et $\beta \in V^*$.

**Remarque**

Des règles de la forme $\alpha \rightarrow \beta_1 \mid \beta_2 \mid ... \mid \beta_n$ avec $n \geq 1$ et pour tout $1 \leq i \leq n$, $\beta_i \in V^*$ peuvent être écrites pour abréger n règles ayant $\alpha$ en partie gauche, de la forme $\alpha \rightarrow \beta_i$.

**Définition**

Les formes sententielles sont les mots atteints en prenant l'axiome S comme mot de départ et en appliquant les règles un nombre fini de fois. Les suites d'applications de règles sont appelés "dérivations".

**Définition**

Les mots du langage caractérisé par la grammaire sont les mots accessibles qui ne sont composés que de symboles terminaux.

**Définition**

Soit $G = (V_T, V_N, S, R)$ une grammaire et $V = V_T \cup V_N$, alors l'ensemble des **formes sententielles** (ou **proto-phrases**) de G est défini récursivement par :

- L'axiome "S" est une **forme sententielle** de G.
- Pour tous $v, x, y, z \in V^*$, si "xyz" est une forme sententielle de G et si $y \rightarrow v \in R$, alors "xvz" est une forme sententielle de G.

Le **langage engendré** par G est $L(G)=\{x \in V^* \mid x \text{ est une forme sententielle de G et } x \in V_T^*\}$.

Une grammaire G est peut être utilisée soit pour générer les phrases du langage L(G) soit pour déterminer si une phrase donnée appartient ou non au langage L(G) :

• La génération consiste à produire des chaînes de symboles par application des règles de la grammaire à partir de son axiome S.

• La vérification (l'analyse) consiste à retrouver la succession d'applications de règles qui a permis d'obtenir un mot en partant de l'axiome S.

**Définition**

Soit G = ($V_T$, $V_N$, S, R) une grammaire : La relation «**dérive directement de**» sur V* notée → est définie par : ∀ z, z' ∈V*, z → z' ↔ ∃ t, u, v, w ∈ V*, z = uvw et z' = utw et v→ t ∈ R.

Si u ∈ $V_T$* (resp. w ∈ $V_T$*) alors uvw → utw est une **dérivation à gauche** (resp. **à droite**). Intuitivement, dans uvw le non terminal v le plus à gauche (resp. à droite) est remplacé pour obtenir utw.

**Notation**

=R→ pour désigner explicitement la règle utilisée.

a =n→b désigne une dérivation de longueur n.

a =*→b désigne une dérivation de longueur quelconque, nous disons alors que a **engendre** b ou, symétriquement, que b **dérive de** a.

**Définition**

Deux grammaires $G_1$ et $G_2$ sont dites équivalentes si $L(G_1) = L(G_2)$.

## 3. Classification des grammaires

### 3. 1. Type 0 : sans contraintes

x → y avec x ∈ V* × $V_N$ × V* et y ∈ V*.

### 3. 2. Type 1 : contextuelle (sensible au contexte)

- x → y avec |x|≤|y|.

Les productions sont soumises à la contrainte que la partie droite de la règle doit contenir au moins autant de symbole que la partie gauche. Le cas particulier S → ε est permis si S n'apparaît pas dans la partie droite d'une règle de G.

- xAy → xBy avec x, y ∈ V*, A ∈ $V_N$ et B ∈ $V^+$ tel que |B| ≥ 1.

Les grammaires de type 1 sont dites sensibles au contexte car leur définition permet le remplacement de A par B uniquement dans le contexte précis où A est entouré par les symboles x et y.

### 3. 3. Type 2 : hors-contexte (algébrique)

X → x avec X ∈ $V_N$ et x ∈ $V^+$.

Le membre gauche de la production est un unique symbole non terminal qui peut être réécrit par une chaîne quelconque du vocabulaire de la grammaire.

### 3. 4. Type 3 : linéaires (régulières à droite (resp. à gauche))

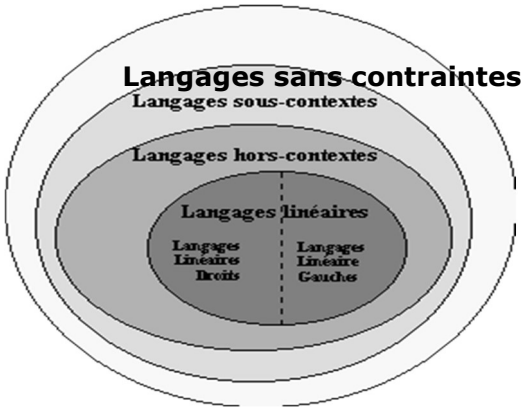
$X \rightarrow x_1 \mid x_2Y$ : linéaire à droite et $X \rightarrow x_1 \mid Yx_2$ : linéaire à gauche avec $X, Y \in V_N$ et $x_1 \in V_T^+$, $x_2 \in V_T^*$.

Le membre gauche de la production est un unique non terminal et le membre de droite est soit une chaîne de terminaux soit une chaîne de terminaux suivie par un seul non terminal.

### 3. 5. Grammaire de Type 4

La restriction des grammaires de type 4 interdit la présence d'un non-terminal à droite de la flèche. Ces grammaires représentent des langages finis.
$X \rightarrow x_1$ avec $X \in V_N$ et $x_1 \in V_T^+$

Ces classes de langage satisfont la relation d'inclusion stricte suivante :



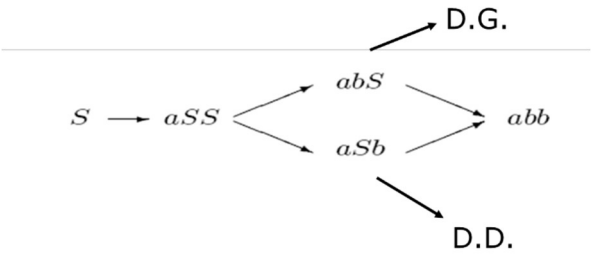

$cl_4 \subset cl_3 \subset cl_2 \subset cl_1 \subset cl_0$

## 4. Dérivations à gauche et à droite

Lorsqu'un mot est engendré par une grammaire, il peut l'être de plusieurs façons. Par exemple dans la grammaire :

$$G : \begin{cases} S \rightarrow aSS \\ S \rightarrow b \end{cases}$$

Le mot abb peut être obtenu par les deux dérivations :




## 5. Cas des Langages Rationnels

**Définition** linéaire → type 3

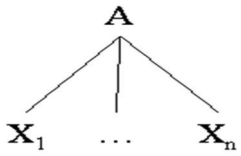
Un langage est linéaire s'il peut être engendré par une grammaire linéaire. Un langage est rationnel si et seulement s'il peut être engendré par une grammaire linéaire gauche (ou droite)

## 6. Représentation des grammaires type 2 avec la norme BNF ("Backus-Naur-Form")

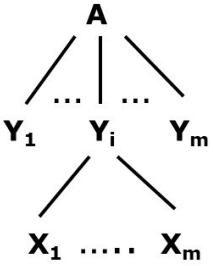
Les symboles non terminaux sont encadrés par des guillemets ("..." ou <<...>>), les symboles terminaux ne sont pas distingués (parfois les non-terminaux sont en majuscule et les terminaux en minuscule). L'axiome est la partie gauche de la première règle énoncée. La disjonction est notée par une barre verticale ( | ). La flèche des règles est remplacée par le signe "::=".

## 7. Arbres de dérivations

L'idée consiste à associer à chaque règle R : A → $X_1$ ... $X_n$ de la grammaire, où A ∈ $V_N$ et ∀ 1 ≤ i ≤ n, $X_i$ ∈ V, la structure d'arbre suivante :




Une dérivation de la forme A =n → $Y_1$...$Y_{i-1}$ $Y_i$ $Y_{i+1}$ ... $Y_m$ = R → $Y_1$ ... $Y_{i-1}$ $X_1$...$X_m$ $Y_{i+1}$ ... $Y_m$ est représentée par l'arbre associé à A =n → $Y_1$... $Y_m$, dans lequel nous remplaçons le symbole non terminal correspondant à $Y_i$ par l'arbre associé à R.



Une chaîne du langage est formée en parcourant les flèches et en recueillant les symboles rencontrés.

**Remarque**

Un arbre de dérivation d'un mot du langage engendré par une grammaire représente une façon de dériver ce mot à partir de l'axiome. La racine de l'arbre est l'axiome, ses feuilles sont les symboles (terminaux) du mot, et ses nœuds internes représentent les applications de règles. Une chaîne du langage est formée en parcourant les flèches et en recueillant les symboles rencontrés.

### 7.1. Ambiguïté

Une grammaire est dite ambiguë si au moins un mot dans son langage a plus d'un arbre de dérivation.